RTS-MA-DS / TAI 负责人 A 证据报告：原稿门控是否真实约束训练与预测

协议 RTS-TAI-PARALLEL-v4.0（PRE-FREEZE）· lane A · base_commit b9dbebe（原稿代码公开版）· LLM：deepseek/deepseek-flash（服务端名称 DeepSeek-V4.1-Flash，全部 1186 次调用返回模型字段均为 deepseek-flash）· 2026-10-19 · 本文所有数字由 scripts/make_report.py 从 results/、paper/ 与 logs/ 读取或复算，可用 ./reproduce.sh --rebuild 重建。

> **状态声明：本报告只包含 DEV 证据，不是 CONF 确认。**G0 = FAIL：FREEZE_SIGNOFF.yaml 未签字，12 个 CONF 与 4 个 TRANSFER 任务仍为 [待冻结]，因此 A2 正式矩阵（144 前缀 / 720 续跑）与 A3 正式矩阵（72 续跑）全部 not_started（共 936 个计划格）。A2/A3 只在 DEV 上做了 pilot：3 个独立基础任务（Spaceship-BIN、Ghouls-MC、House-REG）× 4 类情境 × 2 个开发随机块。ML 族在 DEV 中没有真正的多标签任务（Steel Plate 只有 0.11% 的行带两个标签），按协议预注册为 N/A。3 个任务上的 bootstrap 区间不稳定，只作描述，不支持任何显著性或非劣效措辞。

结论首页：五个问题

Q1　F0 的行为约束真实存在吗？存在，但**只在入口**。入口 gate（BackgroundReviewer）在 3/3 个 DEV 任务上，都在任何 fit 之前拦下了“训练目标缺失”（F01）和“误导性显式目标提示”（F03），结局为 S3。同样的探针换成只记录、不执行判决的 M3 后，全部变成 S5、S6 或 S7。入口之后约束不存在，代码层面有三条原因：（1）target_spec 在运行时没有写保护，NODE_CONTRACTS 只是文档；（2）各阶段 reviewer 只检查“当前 target_spec 与当前文件”是否自洽，从不与入口批准的 C_read 比较；（3）没有任何一条规则约束真实 fit 用的 y、输出列的取值来源，或 ID→预测的配对。

Q2　错误动作实际被改变了吗？入口故障：改变了。A1 的 18 对 F0/M3 运行中，终态不同的有 6 对，全部是 F01 和 F03。A2 的同前缀干预里，情境 (a) 中 F0 把 6/6 条轨迹停在 fit 之前；M3 则 6/6 执行了错误目标的 fit，其中 3/6 交付了错误文件。情境 (b) 中，F0 把 M3 的 6/6 次可见失败变成了 6/6 次合理停止。**入口后故障：没有改变。**情境 (c)（planner 之后 fit 目标漂移）和 (d)（ID↔预测配对错位）共 12 个前缀，F0、M3、M5、G 的终态逐对完全相同：S5 10 个，S7 2 个。这 2 个 S7 来自 Ghouls：漂移目标 color 已经被独热编码，fit 直接报错，并不是被检测出来的。

Q3　与强 M2 相比有什么增量？观测不到任何增量。A3 的 12 对同前缀运行中，F0 与 M2（入口检查完全相同，入口之后只执行 E 类检查）的终态逐对一致：(a) 为 S3×6；(c) 为 S5×4、S7×2。这只能记为“F0 与 M2 方法作用域重合”，不能写成原稿的多阶段贡献。值得注意的是，把同一套 F0 规则只在末端重放一次（M4），在 (c) 中拦下了 6/6；但 M4 在 (a) 中失败（6/6 发生错误 fit，3/6 不安全交付）。可见问题不在“检查几次”，而在“检查对象”：F0 入口之后从不重新验证契约不变量（Y ⊆ train、Y ∩ test = ∅）。

Q4　是否只是更多拒绝？在干净任务上，F0 不多拒绝：A0 为 24/24 S1，A1 的 C00 为 6/6 S1；LLM-off 重放下，F0 与 M0、M2、M3、M4、M5、G 的产出逐字节一致。但有三点需要说明。(i) F0 的拦截全部发生在入口，而且先做两次注定无效的重试：reader 重试时把自己上一次的 target_spec 当作显式输入，所以结论不会变。与立即阻断（M5）相比，结局相同，但每对多花 4 次 LLM 调用。(ii) 有 1 个合法变体被误拦：Steel B01，reader 从 overview 文本中把 id 解析成了目标，入口以“id 泄漏”阻断，结局 S4。(iii) 主要问题不是拒绝过多，而是放行了错误：合法别名 B01 在 3 个 DEV 任务上都没被拦，但输出列被 range(n) 合成的“ID”填充后交付（S6、S6、S5）。默认重试在任何故障情境中都没有产生一次修复（S2 = 0）。

Q5　哪些判断没有可靠的观察条件？（1）CONF 层面的一切，因为 G0 未通过，也就无法给出 ML 族的结论。（2）原稿 16 个旧故障包和 Table 3 消融代码都不在仓库里：Table 5 的 2/3 冲突只能从代码推断，“No reviewer gates”只能重建，耗时 8.40 s 也复现不出来。（3）原稿使用的 MiniMax-M2.7 已停服（HTTP 410），旧 LLM 配置无法复现。（4）列名不变、只改内容的目标漂移，oracle 只记录了 y 指纹，没有作为判定依据。（5）4 路并发下的墙钟时间只能作描述性记录。（6）F0 在 (c)/(d) 中没有 fit 之前的 gate，所以错误 fit 在分叉点之前就已发生；“是否发生错误 fit”这一项在各分支间按构造相同，分支差异只能来自 gate 之后的重新 fit 和交付。（7）3 个任务的区间不稳定，不能作统计推断。

运行账本

计划格共 1223 个：DEV 287 个，其中可运行 223 个、预注册 N/A 64 个；CONF 936 个，因 G0 未通过全部 not_started。223 个 DEV 格全部启动并完成，包括 24 个 A2 前缀快照，所有前缀都在声明的 gate 前分叉成功。其余 199 个终端运行各自恰好落入一个终态：S1 43、S3 50、S4 1、S5 67、S6 7、S7 31、S8 0。120 个分支的 state、candidate、RNG 哈希与快照全部一致（G4）。真实 LLM 调用共 1186 次（每次调用只计一次），输入/输出 token 为 5404175/936733，API 错误 0 次；服务商价格未冻结，费用记为 NA。

质量门控（G0–G6 与本 lane 实验门控）

experiment_id	gate_id	status	checked_count	eligible_count	reason
ALL	G0	FAIL	0	1	unsigned; CONF/TRANSFER identities [待冻结] -> only DEV allowed; no CONF claim
DEV	G1	PASS	108	108	file mutations verified=True; runtime injections not verified=0 []; test.csv target leaks=[]
DEV	G2	PASS	8	8	hook equivalence=True; DEV tasks with >=1 clean F0 delivery=8; M0 clean deliveries=2/2; M3=2/2
DEV	G3	PASS	223	223	started=223; started without unique terminal=0; planned but not started=0 (listed in plan_ledger with status)
A2/A3	G4	PASS	120	120	branches with hash mismatch=0; private-test leaks=[]
DEV	G5	PASS(partial matrix: DEV pilot only)	223	223	every table/figure regenerated from raw events; manual check of favourable and unfavourable records in paper/cases;

experiment_id	gate_id	status	checked_count	eligible_count	reason
DEV	G6	PASS	4	4	QC / USABLE / SUPPORT recorded separately per experiment; DEV pilot capped at CLAIM_DIRECTIONAL
A0	A0-QC	PASS	1	1	identifiable version (public release); F0/M0/M3 differences located at function level; M0/M3 complete >=2 clean DEV
A1	A1-QC	PASS	36	48	48 cells: run=36, N/A=12; consistency claims use fit/predict/serialize hook events (not agent text); runs with a re
A2	A2-QC	PASS(DEV pilot)	24	24	prefixes forked=24/24; every launched branch has one terminal; formal 144-prefix CONF matrix not started (G0)
A3	A3-QC	PASS(DEV pilot)	12	12	M2 uses identical intake path (same snapshot at intake for context a; same post-intake prefix for context c)

A0 旧结果核对、无门控可运行性与代码语义审计

旧结果核对。在 8 个原稿 DEV 任务上，用原始任务包、原稿预设（q、H、metric hint）和 technical-only 模式各跑 3 次，24/24 均交付有效且语义正确（S1），复现了原稿 Table 2 的 24/24。7 个分类任务中，5 个的 CV 分数与原稿相差在 0.002 以内；Spaceship 高 0.011；Steel 低 0.006（F0 对该任务用 holdout 选模型）；回归任务 House 的 RMSE 差约 1%。原稿称分数“在重复间确定、标准差为 0”，这一点没有复现：分类任务重复间标准差为 0.0002–0.0013，因为特征工程和建模配置由 LLM 规划。由于 LLM 后端、机器和并发都已不同，差异归因于配置，不归因于代码（代码就是 b9dbebe）。墙钟时间不可比。**敏感性分析（非预注册规则）：**F0 对 Spaceship 的 29 次交付全是概率值，没有一次输出任务要求的 True/False 标签，原因是 reader 把布尔型的 sample 值当成 [0,1] 数值，推断为 probability。原稿把 Spaceship 记为 3/3 有效，说明原稿的有效性判据不检查取值域。按严格的标签域规则，这 29 次交付全部会改判为 S6（results/sensitivity_strict_label_domain.csv）。另外，House 私有测试集的 RMSE（约 58k）受两个著名离群点（Id 1299、524）主导，去掉后约 25.7k。分数只是次要指标。

task_id	manuscript_metric	原稿分数	当前均值	当前SD	Δ	原稿有效	当前有效	原稿秒	当前秒	终态
DEV-BIN-SPACESHIP	Acc.	0.7934	0.8048	0.001	0.0114	3/3	3/3	31.3	76.0	S1|S1|S1
DEV-BIN-TITANIC	ROC-AUC	0.877	0.8754	0.0013	−0.0016	3/3	3/3	16.4	46.8	S1|S1|S1
DEV-BIN-BANK	ROC-AUC	0.8892	0.8891	0.0002	−0.0001	3/3	3/3	41.4	65.3	S1|S1|S1
DEV-MC-ACADEMIC	Macro-F1	0.7938	0.7929	0.0006	−0.0009	3/3	3/3	60.6	64.5	S1|S1|S1
DEV-MC-GHOULS	Macro-F1	0.754	0.7533	0.0009	−0.0007	3/3	3/3	16.6	36.7	S1|S1|S1
DEV-MC-OBESITY	Macro-F1	0.8941	0.8935	0.0007	−0.0006	3/3	3/3	114.7	110.4	S1|S1|S1
DEV-ML-STEEL	ROC-AUC	0.8883	0.8826	0.0004	−0.0057	3/3	3/3	276.6	295.1	S1|S1|S1
DEV-REG-HOUSE	Neg. RMSE	−29622.8	−29918.3671	153.4003	−295.5671	3/3	3/3	49.0	86.5	S1|S1|S1

无门控可运行性。正确实现的 M0（只取消 S 类判决，状态写入和路由保留）在 2 个干净 DEV 任务上 2/2 完成，M3 同样 2/2。把 gate 节点替换为 pass-through、路由保持不变的重建版本则 0/2 完成：latest_review_status 永远不被写入，route_after_reviewer 把 None 当作 retry，图在 reader 和 background_reviewer 之间空转直到递归上限。这复现了原稿 Table 3 中“No reviewer gates：干净完成 0/4、FP 4/4”的结局，说明那一行反映的是接口断裂，不是语义门控的效果。但重建版本耗时约 172 s，与原稿的 8.40 s 不一致，所以旧消融的具体实现仍无法核验。“No target-spec / Schema-only / No semantic align.”三行在 b9dbebe 中没有对应开关，无法复跑。16 个旧故障包也不在仓库或项目目录中，标记为 not_reproducible（D-07）。

source	variant	clean_completion	clean_valid	stop	fp	time_s
manuscript Table 3	Full RTS-MA-DS	4/4	4/4	2/2	0/4	70.84
manuscript Table 3	No target-spec	4/4	4/4	0/2	0/4	123.56
manuscript Table 3	Schema-only	4/4	4/4	0/2	0/4	131.83
manuscript Table 3	No semantic align.	4/4	4/4	0/2	0/4	132.82
manuscript Table 3	No reviewer gates	0/4	0/4	2/2	4/4	8.4
lane A DEV (2 clean tasks: Titanic, Ghouls)	F0 public release (current)	2/2	2/2	not run (manuscript fault packages unavailable)	0/2	42.78
lane A DEV (2 clean tasks: Titanic, Ghouls)	M0 corrected: semantic verdicts not enforced, state/routing kept	2/2	2/2	not run (manuscript fault packages unavailable)	0/2	39.22
lane A DEV (2 clean tasks: Titanic, Ghouls)	M3 shadow: all verdicts computed, none enforced	2/2	2/2	not run (manuscript fault packages unavailable)	0/2	51.93
lane A DEV (2 clean tasks: Titanic, Ghouls)	reconstruction of 'No reviewer gates': gate nodes removed, routing kept	0/2	0/2	not run (manuscript fault packages unavailable)	2/2	172.43

代码语义审计要点（详见 results/A0/A0_method_diff.md，均附行号）：

（1）Algorithm 1 第 3、4 行规定缺目标或目标泄漏时返回 fatal，代码实际返回 retry，到第 3 次尝试才 fatal。这本可以解释 Table 5 中“缺训练目标”只拦下 2/3 的冲突，但旧故障包缺失，无法核验。

（2）第 6、7 行的 Aligned(Y,O,f) 和多标签完整性检查没有实现。_submission_spec 把所有非目标列都当作 ID 列；model_building 在 O 为空时默认 O=Y，并用 range(n) 合成测试集中不存在的“ID”列（model_tools.py:1738）。这是 B01 和 F03–M3 静默错误的共同通道。

（3）task_family 取自 reader LLM 的 predicted_task_type，入口没有确定性复核。

（4）重试预算 N_max=3 计的是尝试次数，即最多重试 2 次。只有 feature_engineering 和 model_building 的重试会把字段级诊断交给 LLM planner；data_cleaning 和 indepth_eda 的 planner 是确定性的，重试只会重复同一个计划。

（5）data_cleaning 会静默删除泄漏进测试集的目标列，后续 gate 和 M4 的末端检查因此看不到证据。

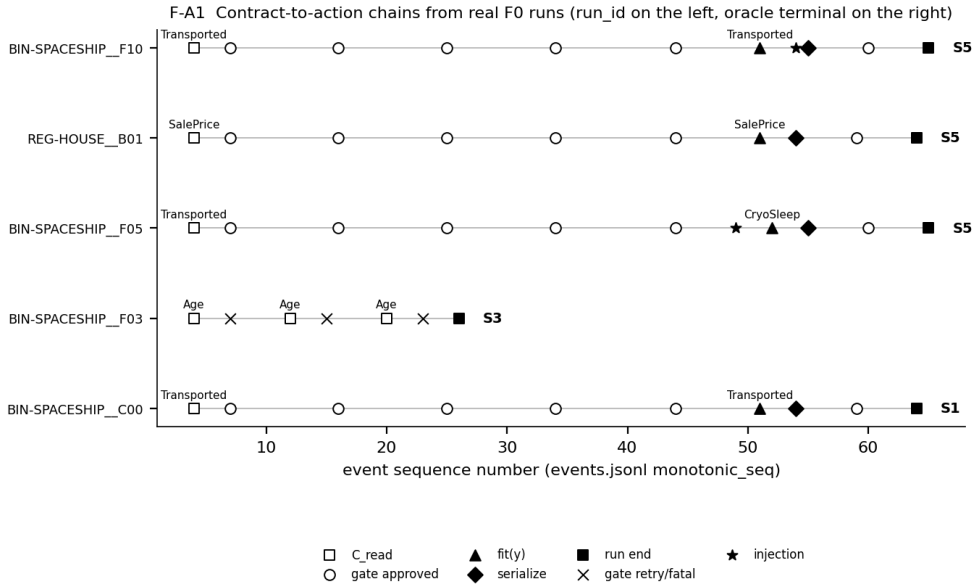
（6）原稿 RQ5 报告的模型构建平均耗时 97.62 s，大于 Table 2 的平均总耗时 75.8 s，说明这两组时间数据来自不同样本，来源无法核验。

A1 C_gold、C_read 与真实 fit/output 的绑定

48 个计划格中，36 个已运行，12 个为 ML 族预注册 N/A。每条轨迹都有 C_read、gate 判决（含影子判决）以及 fit/predict/serialize hook 事件；判定只依据事件和磁盘产物，不读取 agent 的文字。**入口**：F01 和 F03 被 F0 拦截，且定位到具体列名（exact_match）。**阶段漂移**：F05 中 C_read 正确，但 fit 消费的是被改写的目标（Spaceship 为 CryoSleep，House 为 GrLivArea），所有后续 gate 都放行，结局 S5。**实际消费脱钩**：B01 的契约和 fit 都正确，但交付文件的输出列是合成 ID（Spaceship、Ghouls 为 S6，House 为 S5）。**输出错配**：F10 在 predict() 之后打乱了 ID↔预测配对，列、行数和空值检查全部通

过，结局 S5。以上入口后的 9 对，F0 与 M3 终态全部相同。Steel 是原稿 ML 代表，只用于 A0：其 F01 被拦下，但理由不对——reader 的模糊提示匹配把特征列 Steel_Plate_Thickness 当成目标，再按“泄漏”拦截（只做到 partial 定位）。

任务	探针	F0 终态	M3 终态	F0 C_read	F0 fit y	F0 失败来源（事件判定）	定位
BIN-SPACESHIP	B01	S6	S6	Transported	Transported	consumption_decoupling(output role filled by synthesized ids, not predictions)	none
BIN-SPACESHIP	C00	S1	S1	Transported	Transported	consistent(C_gold = C_read = C_used, mapping valid)	none
BIN-SPACESHIP	F01	S3	S7	Transported		stopped_before_fit	exact_match
BIN-SPACESHIP	F03	S3	S7	Age		initial_contract_error(reader resolved a different target)	exact_match
BIN-SPACESHIP	F05	S5	S5	Transported	CryoSleep	stage_drift(C_read correct, fit consumed a different target/family)	none
BIN-SPACESHIP	F10	S5	S5	Transported	Transported	output_mismatch(ID->prediction pairing altered after predict())	none
MC-GHOULS	B01	S6	S6	type	type	consumption_decoupling(output role filled by synthesized ids, not predictions)	none
MC-GHOULS	C00	S1	S1	type	type	consistent(C_gold = C_read = C_used, mapping valid)	none
MC-GHOULS	F01	S3	S7	type		stopped_before_fit	exact_match
MC-GHOULS	F03	S3	S6	hair_length		initial_contract_error(reader resolved a different target)	exact_match
MC-GHOULS	F05	S7	S7	type		no_fit(execution failure)	none
MC-GHOULS	F10	S5	S5	type	type	output_mismatch(ID->prediction pairing altered after predict())	none
ML-STEEL	B01	S4	(A0 only)	id|Pastry|Z_Scratch|K_Scatch		initial_contract_error(reader resolved a different target)	none
ML-STEEL	C00	S1	(A0 only)	Pastry|Z_Scratch|K_Scatch|St	Pastry|Z_Scratch|K_Scatch|St	consistent(C_gold = C_read = C_used, mapping valid)	none
ML-STEEL	F01	S3	(A0 only)	Steel_Plate_Thickness		initial_contract_error(reader resolved a different target)	partial
ML-STEEL	F03	S3	(A0 only)	Pixels_Areas		initial_contract_error(reader resolved a different target)	exact_match
ML-STEEL	F05	S7	(A0 only)	Pastry|Z_Scratch|K_Scatch|St	Steel_Plate_Thickness	stage_drift(C_read correct, fit consumed a different target/family)	none
REG-HOUSE	B01	S5	S5	SalePrice	SalePrice	consumption_decoupling(output role filled by synthesized ids, not predictions)	none
REG-HOUSE	C00	S1	S1	SalePrice	SalePrice	consistent(C_gold = C_read = C_used, mapping valid)	none
REG-HOUSE	F01	S3	S7	SalePrice		stopped_before_fit	exact_match
REG-HOUSE	F03	S3	S5	LotArea		initial_contract_error(reader resolved a different target)	exact_match
REG-HOUSE	F05	S5	S5	SalePrice	GrLivArea	stage_drift(C_read correct, fit consumed a different target/family)	none
REG-HOUSE	F10	S5	S5	SalePrice	SalePrice	output_mismatch(ID->prediction pairing altered after predict())	none



逐事件实例（paper/cases/）。正例：positive_01（Spaceship F01，入口 3 次尝试后 fatal，全程无 fit）、positive_02（Ghouls F03）。反例：counter_01（F05 漂移后被交付）、counter_02（House B01 交付合成 ID）、counter_03（F10 置换被交付；人工核对：交付文件的 ID 顺序与测试集一致，预测值是 predict() 输出的一个置换，1739 行中只有 4 行原位）、counter_04（Steel F01，结局对、理由错）。

A2 同一候选动作下的放行—阻断—恢复配对干预（DEV pilot）

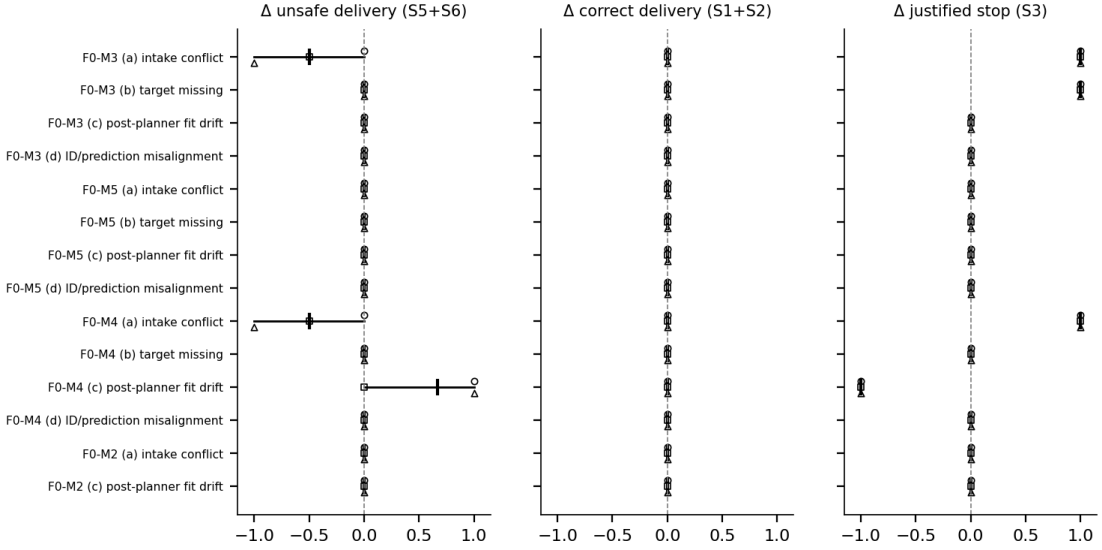
24 个前缀全部在声明的 gate 前冻结快照，从快照恢复后 state、candidate、RNG 三个哈希全部一致；每个分支只切换 gate 策略。情境 (a)(b) 中 G 按预注册记为 N/A，因为入口重试没有诊断通道。**(a) 入口目标冲突**：F0 与 M5 都是 S3×6，但 F0 每对多用 4 次调用；M3 和 M4 都执行了错误 fit（6/6），其中 3/6 交付不安全文件。M4 的末端检查失效，是因为 data_cleaning 已把“泄漏”的提示列从测试集中删掉了。**(b) 缺目标**：F0、M5、M4 都是 S3×6，M3 是 S7×6。**(c) planner 后漂移**：除 M4 外所有分支均为 S5×4、S7×2，M4 为 S3×6。**(d) ID/预测错配**：所有分支 S5×6。在任何故障情境中，没有一个分支产生正确交付（S1+S2 = 0），所以 F0—M5、G—F0 的“恢复”主张均不成立。按任务书，主张必须收窄为：F0 的执行权只在入口有效。

context	method_id	n	gate 后下一动作	分叉后错误 fit	错误交付	S1	S2	S3	S4	S5	S6	S7	S8	分叉后调用	严格同前缀
a_recoverable_intake_conflict	M3_SHADOW	6	planner	6.0	3.0	0.0	0.0	0.0	0.0	2.0	1.0	3.0	0.0	8.0	6/6
a_recoverable_intake_conflict	M5_BLOCK_ONLY	6	END(aborted)	0.0	0.0	0.0	0.0	6.0	0.0	0.0	0.0	0.0	0.0	1.0	6/6
a_recoverable_intake_conflict	G_GENERIC_RETRY	0													
a_recoverable_intake_conflict	F0_ORIGINAL	6	reader(retry)	0.0	0.0	0.0	0.0	6.0	0.0	0.0	0.0	0.0	0.0	5.0	6/6
a_recoverable_intake_conflict	M4_END_ONLY	6	planner	6.0	3.0	0.0	0.0	0.0	0.0	2.0	1.0	3.0	0.0	10.0	6/6
a_recoverable_intake_conflict	M2_INTAKE_ONLY_STRONG	6	reader(retry)	0.0	0.0	0.0	0.0	6.0	0.0	0.0	0.0	0.0	0.0	5.0	6/6
b_unrecoverable_missing_target	M3_SHADOW	6	planner	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	6.0	0.0	8.0	6/6
b_unrecoverable_missing_target	M5_BLOCK_ONLY	6	END(aborted)	0.0	0.0	0.0	0.0	6.0	0.0	0.0	0.0	0.0	0.0	1.0	6/6
b_unrecoverable_missing_target	G_GENERIC_RETRY	0													
b_unrecoverable_missing_target	F0_ORIGINAL	6	reader(retry)	0.0	0.0	0.0	0.0	6.0	0.0	0.0	0.0	0.0	0.0	5.0	6/6
b_unrecoverable_missing_target	M4_END_ONLY	6	planner	0.0	0.0	0.0	0.0	6.0	0.0	0.0	0.0	0.0	0.0	8.0	6/6
b_unrecoverable_missing_target	M2_INTAKE_ONLY_STRONG	0													
c_post_planner_fit_target_drift	M3_SHADOW	6	summarizer	0.0	4.0	0.0	0.0	0.0	0.0	4.0	0.0	2.0	0.0	1.0	6/6
c_post_planner_fit_target_drift	M5_BLOCK_ONLY	6	END(aborted)|summarizer	0.0	4.0	0.0	0.0	0.0	0.0	4.0	0.0	2.0	0.0	1.0	6/6
c_post_planner_fit_target_drift	G_GENERIC_RETRY	6	planner(retry:model_building)|summarizer	0.0	4.0	0.0	0.0	0.0	0.0	4.0	0.0	2.0	0.0	2.33	6/6
c_post_planner_fit_target_drift	F0_ORIGINAL	6	planner(retry:model_building)|summarizer	0.0	4.0	0.0	0.0	0.0	0.0	4.0	0.0	2.0	0.0	2.33	6/6
c_post_planner_fit_target_drift	M4_END_ONLY	6	END(aborted)	0.0	0.0	0.0	0.0	6.0	0.0	0.0	0.0	0.0	0.0	1.0	6/6
c_post_planner_fit_target_drift	M2_INTAKE_ONLY_STRONG	6	planner(retry:model_building)|summarizer	0.0	4.0	0.0	0.0	0.0	0.0	4.0	0.0	2.0	0.0	2.33	6/6
d_predict_id_role_misalignment	M3_SHADOW	6	summarizer	0.0	6.0	0.0	0.0	0.0	0.0	6.0	0.0	0.0	0.0	1.0	6/6
d_predict_id_role_misalignment	M5_BLOCK_ONLY	6	summarizer	0.0	6.0	0.0	0.0	0.0	0.0	6.0	0.0	0.0	0.0	1.0	6/6
d_predict_id_role_misalignment	G_GENERIC_RETRY	6	summarizer	0.0	6.0	0.0	0.0	0.0	0.0	6.0	0.0	0.0	0.0	1.0	6/6
d_predict_id_role_misalignment	F0_ORIGINAL	6	summarizer	0.0	6.0	0.0	0.0	0.0	0.0	6.0	0.0	0.0	0.0	1.0	6/6
d_predict_id_role_misalignment	M4_END_ONLY	6	summarizer	0.0	6.0	0.0	0.0	0.0	0.0	6.0	0.0	0.0	0.0	1.0	6/6
d_predict_id_role_misalignment	M2_INTAKE_ONLY_STRONG	0													

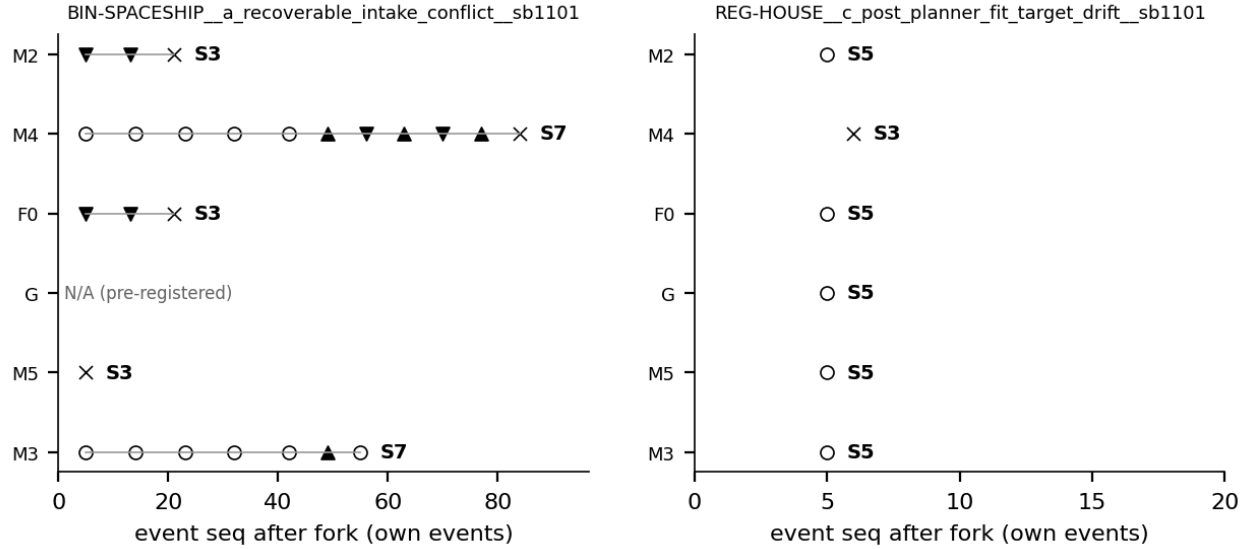
contrast	metric	n_tasks	n_pairs	task_level_mean	boot95_low	boot95_high	per_task	direction
F0−M2	d_unsafe_delivery_S5S6	3	12	0.0	0.0	0.0	{"DEV−BIN−SPACESHIP": 0.0, "DEV−MC−GHOULS": 0.0, "DEV−REG−HOUSE": 0.0}	0|0|0
F0−M2	d_correct_delivery_S1S2	3	12	0.0	0.0	0.0	{"DEV−BIN−SPACESHIP": 0.0, "DEV−MC−GHOULS": 0.0, "DEV−REG−HOUSE": 0.0}	0|0|0
F0−M2	d_justified_stop_S3	3	12	0.0	0.0	0.0	{"DEV−BIN−SPACESHIP": 0.0, "DEV−MC−GHOULS": 0.0, "DEV−REG−HOUSE": 0.0}	0|0|0
F0−M2	d_wrong_training_seconds_after_fork	3	12	0.0	0.0	0.0	{"DEV−BIN−SPACESHIP": 0.0, "DEV−MC−GHOULS": 0.0, "DEV−REG−HOUSE": 0.0}	0|0|0
F0−M2	d_api_calls_own	3	12	0.0	0.0	0.0	{"DEV−BIN−SPACESHIP": 0.0, "DEV−MC−GHOULS": 0.0, "DEV−REG−HOUSE": 0.0}	0|0|0
F0−M3	d_unsafe_delivery_S5S6	3	24	−0.125	−0.25	0.0	{"DEV−BIN−SPACESHIP": 0.0, "DEV−MC−GHOULS": −0.125, "DEV−REG−HOUSE": −0.25}	0|−|−
F0−M3	d_correct_delivery_S1S2	3	24	0.0	0.0	0.0	{"DEV−BIN−SPACESHIP": 0.0, "DEV−MC−GHOULS": 0.0, "DEV−REG−HOUSE": 0.0}	0|0|0
F0−M3	d_justified_stop_S3	3	24	0.5	0.5	0.5	{"DEV−BIN−SPACESHIP": 0.5, "DEV−MC−GHOULS": 0.5, "DEV−REG−HOUSE": 0.5}	+|+|+
F0−M3	d_wrong_training_seconds_after_fork	3	24	−2.0374	−5.5661	−0.0558	{"DEV−BIN−SPACESHIP": −0.0558, "DEV−MC−GHOULS": −0.4902, "DEV−REG−HOUSE": −5.5661}	−|−|−
F0−M3	d_api_calls_own	3	24	−1.1667	−1.5	−0.5	{"DEV−BIN−SPACESHIP": −1.5, "DEV−MC−GHOULS": −0.5, "DEV−REG−HOUSE": −1.5}	−|−|−
F0−M4	d_unsafe_delivery_S5S6	3	24	0.0417	−0.125	0.25	{"DEV−BIN−SPACESHIP": 0.25, "DEV−MC−GHOULS": −0.125, "DEV−REG−HOUSE": 0.0}	+|−|0
F0−M4	d_correct_delivery_S1S2	3	24	0.0	0.0	0.0	{"DEV−BIN−SPACESHIP": 0.0, "DEV−MC−GHOULS": 0.0, "DEV−REG−HOUSE": 0.0}	0|0|0

contrast	metric	n_tasks	n_pairs	task_level_mean	boot95_low	boot95_high	per_task	direction
F0−M4	d_justified_stop_S3	3	24	0.0	0.0	0.0	{"DEV−BIN−SPACESHIP": 0.0, "DEV−MC−GHOULS": 0.0, "DEV−REG−HOUSE": 0.0}	0|0|0
F0−M4	d_wrong_training_seconds_after_fork	3	24	−2.2129	−5.9431	−0.1653	{"DEV−BIN−SPACESHIP": −0.1653, "DEV−MC−GHOULS": −0.5304, "DEV−REG−HOUSE": −5.9431}	−|−|−
F0−M4	d_api_calls_own	3	24	−1.6667	−2.5	−1.0	{"DEV−BIN−SPACESHIP": −2.5, "DEV−MC−GHOULS": −1.0, "DEV−REG−HOUSE": −1.5}	−|−|−
F0−M5	d_unsafe_delivery_S5S6	3	24	0.0	0.0	0.0	{"DEV−BIN−SPACESHIP": 0.0, "DEV−MC−GHOULS": 0.0, "DEV−REG−HOUSE": 0.0}	0|0|0
F0−M5	d_correct_delivery_S1S2	3	24	0.0	0.0	0.0	{"DEV−BIN−SPACESHIP": 0.0, "DEV−MC−GHOULS": 0.0, "DEV−REG−HOUSE": 0.0}	0|0|0
F0−M5	d_justified_stop_S3	3	24	0.0	0.0	0.0	{"DEV−BIN−SPACESHIP": 0.0, "DEV−MC−GHOULS": 0.0, "DEV−REG−HOUSE": 0.0}	0|0|0
F0−M5	d_wrong_training_seconds_after_fork	3	24	0.0	0.0	0.0	{"DEV−BIN−SPACESHIP": 0.0, "DEV−MC−GHOULS": 0.0, "DEV−REG−HOUSE": 0.0}	0|0|0
F0−M5	d_api_calls_own	3	24	2.3333	2.0	3.0	{"DEV−BIN−SPACESHIP": 2.0, "DEV−MC−GHOULS": 3.0, "DEV−REG−HOUSE": 2.0}	+|+|+
G−F0	d_unsafe_delivery_S5S6	3	12	0.0	0.0	0.0	{"DEV−BIN−SPACESHIP": 0.0, "DEV−MC−GHOULS": 0.0, "DEV−REG−HOUSE": 0.0}	0|0|0
G−F0	d_correct_delivery_S1S2	3	12	0.0	0.0	0.0	{"DEV−BIN−SPACESHIP": 0.0, "DEV−MC−GHOULS": 0.0, "DEV−REG−HOUSE": 0.0}	0|0|0
G−F0	d_justified_stop_S3	3	12	0.0	0.0	0.0	{"DEV−BIN−SPACESHIP": 0.0, "DEV−MC−GHOULS": 0.0, "DEV−REG−HOUSE": 0.0}	0|0|0
G−F0	d_wrong_training_seconds_after_fork	3	12	0.0	0.0	0.0	{"DEV−BIN−SPACESHIP": 0.0, "DEV−MC−GHOULS": 0.0, "DEV−REG−HOUSE": 0.0}	0|0|0
G−F0	d_api_calls_own	3	12	0.0	0.0	0.0	{"DEV−BIN−SPACESHIP": 0.0, "DEV−MC−GHOULS": 0.0, "DEV−REG−HOUSE": 0.0}	0|0|0

F-A2 Task-level paired effects per context (DEV pilot, 3 tasks x 2 seed blocks). Bar: task-mean with task-bootstrap 95% (unstable, n=3); markers: per task (o Spaceship, □ Ghouls, △ House). Negative Δ unsafe = fewer unsafe deliveries for the first method.



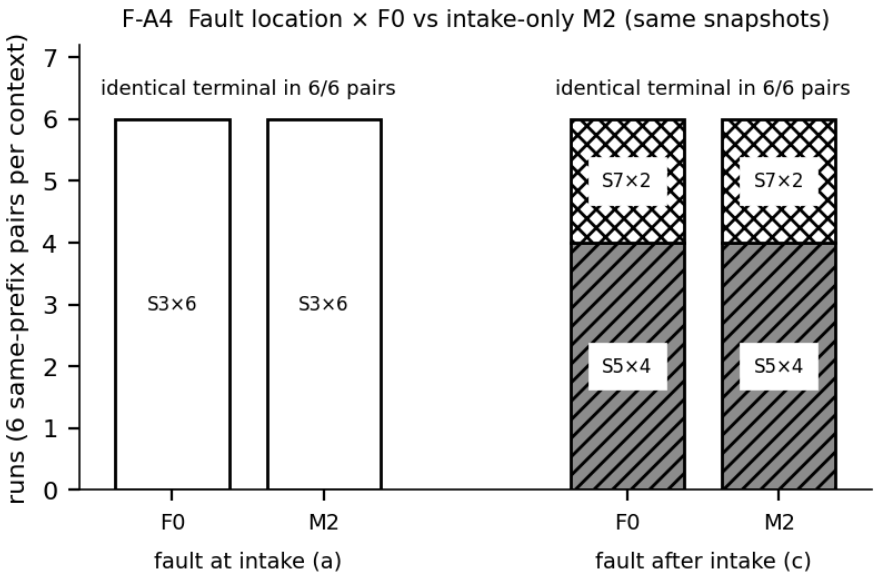
F-A3 Same-prefix branches from identical snapshots (o approved, v retry, x fatal, ^ fit, ◇ file write; terminal at right)



A3 强一次性语义检查是否已经足够？（DEV pilot）

代码断言：M2 与 F0 共享同一个入口实现，在 (a) 中二者的入口判决轨迹完全一致（都是 retry、retry、fatal）。(c) 的注入发生在入口之后，二者此后唯一的研究性差异是 S 类判决是否执行。结果是 12/12 对终态相同，因此标为“F0 与 M2 方法作用域重合”：在入口之后产生的语义漂移上，原稿机制相对强入口检查没有增量。这是一个可用的零效应发现，不是实验失败。

context	task_id	seed_block	F0_terminal	M2_terminal	d_unsafe_delivery_S5S6	d_correct_delivery_S1S2	strict_common_prefix
a_recoverable_intake_conflict	DEV-BIN-SPACESHIP	1101	S3	S3	0	0	True
a_recoverable_intake_conflict	DEV-BIN-SPACESHIP	1102	S3	S3	0	0	True
c_post_planner_fit_target_drift	DEV-BIN-SPACESHIP	1101	S5	S5	0	0	True
c_post_planner_fit_target_drift	DEV-BIN-SPACESHIP	1102	S5	S5	0	0	True
a_recoverable_intake_conflict	DEV-MC-GHOULS	1101	S3	S3	0	0	True
a_recoverable_intake_conflict	DEV-MC-GHOULS	1102	S3	S3	0	0	True
c_post_planner_fit_target_drift	DEV-MC-GHOULS	1101	S7	S7	0	0	True
c_post_planner_fit_target_drift	DEV-MC-GHOULS	1102	S7	S7	0	0	True
a_recoverable_intake_conflict	DEV-REG-HOUSE	1101	S3	S3	0	0	True
a_recoverable_intake_conflict	DEV-REG-HOUSE	1102	S3	S3	0	0	True
c_post_planner_fit_target_drift	DEV-REG-HOUSE	1101	S5	S5	0	0	True
c_post_planner_fit_target_drift	DEV-REG-HOUSE	1102	S5	S5	0	0	True



主张账本、不可观察边界与下一步

主张收窄。DEV pilot 支持的说法是：RTS-MA-DS 的语义门控在入口有效，能在 fit 之前阻止训练目标缺失和误导性显式目标（3 个 DEV 任务，方向一致）。它对入口之后的契约漂移、输出角色错配和 ID 配对置换没有约束，也没有表现出修复能力。不支持的说法有：“各阶段 reviewer 持续核查契约”“契约被冻结并约束建模”“默认 retry 恢复正确交付”。**不可观察的边界**见 Q5。

claim_id	primary_contrast	estimate	ci_low	ci_high	per_task_direction	support_level
A-C1:a_recoverable_intake_conflict:d_unsafe_delivery_S5S6	F0-M3	-0.5	-1.0	0.0	0|-|-	CLAIM_DIRECTIONAL(DEV pilot)
A-C1:b_unrecoverable_missing_target:d_unsafe_delivery_S5S6	F0-M3	0.0	0.0	0.0	0|0|0	CLAIM_NOT_SUPPORTED(no difference)
A-C1:c_post_planner_fit_target_drift:d_unsafe_delivery_S5S6	F0-M3	0.0	0.0	0.0	0|0|0	CLAIM_NOT_SUPPORTED(no difference)
A-C1:d_predict_id_role_misalignment:d_unsafe_delivery_S5S6	F0-M3	0.0	0.0	0.0	0|0|0	CLAIM_NOT_SUPPORTED(no difference)
A-C1:ALL:d_unsafe_delivery_S5S6	F0-M3	-0.125	-0.25	0.0	0|-|-	CLAIM_DIRECTIONAL(DEV pilot)
A-C2:a_recoverable_intake_conflict:d_unsafe_delivery_S5S6	F0-M2	0.0	0.0	0.0	0|0|0	CLAIM_NOT_SUPPORTED(no difference)
A-C2:c_post_planner_fit_target_drift:d_unsafe_delivery_S5S6	F0-M2	0.0	0.0	0.0	0|0|0	CLAIM_NOT_SUPPORTED(no difference)
A-C2:ALL:d_unsafe_delivery_S5S6	F0-M2	0.0	0.0	0.0	0|0|0	CLAIM_NOT_SUPPORTED(no difference)
A-C3a:a_recoverable_intake_conflict:d_correct_delivery_S1S2	F0-M5	0.0	0.0	0.0	0|0|0	CLAIM_NOT_SUPPORTED(no difference)

claim_id	primary_contrast	estimate	ci_low	ci_high	per_task_direction	support_level
A–C3a:b_unrecoverable_missing_target:d_correct_delivery_S1S2	F0–M5	0.0	0.0	0.0	0|0|0	CLAIM_NOT_SUPPORTED(no difference)
A–C3a:c_post_planner_fit_target_drift:d_correct_delivery_S1S2	F0–M5	0.0	0.0	0.0	0|0|0	CLAIM_NOT_SUPPORTED(no difference)
A–C3a:d_predict_id_role_misalignment:d_correct_delivery_S1S2	F0–M5	0.0	0.0	0.0	0|0|0	CLAIM_NOT_SUPPORTED(no difference)
A–C3a:ALL:d_correct_delivery_S1S2	F0–M5	0.0	0.0	0.0	0|0|0	CLAIM_NOT_SUPPORTED(no difference)
A–C3b:c_post_planner_fit_target_drift:d_correct_delivery_S1S2	G–F0	0.0	0.0	0.0	0|0|0	CLAIM_NOT_SUPPORTED(no difference)
A–C3b:d_predict_id_role_misalignment:d_correct_delivery_S1S2	G–F0	0.0	0.0	0.0	0|0|0	CLAIM_NOT_SUPPORTED(no difference)
A–C3b:ALL:d_correct_delivery_S1S2	G–F0	0.0	0.0	0.0	0|0|0	CLAIM_NOT_SUPPORTED(no difference)
A–C4:a_recoverable_intake_conflict:d_unsafe_delivery_S5S6	F0–M4	−0.5	−1.0	0.0	0|–|–	CLAIM_DIRECTIONAL(DEV pilot)
A–C4:b_unrecoverable_missing_target:d_unsafe_delivery_S5S6	F0–M4	0.0	0.0	0.0	0|0|0	CLAIM_NOT_SUPPORTED(no difference)
A–C4:c_post_planner_fit_target_drift:d_unsafe_delivery_S5S6	F0–M4	0.6667	0.0	1.0	+|0|+	CLAIM_NOT_SUPPORTED(reverse direction)
A–C4:d_predict_id_role_misalignment:d_unsafe_delivery_S5S6	F0–M4	0.0	0.0	0.0	0|0|0	CLAIM_NOT_SUPPORTED(no difference)
A–C4:ALL:d_unsafe_delivery_S5S6	F0–M4	0.0417	−0.125	0.25	+|–|0	CLAIM_NOT_SUPPORTED(reverse direction)

完整主张账本（含次要估计量、反例 pair_id 与允许的论文措辞）：results/claims.csv；文字版：results/A_claim_ledger.md。

进入 CONF 之前需要：签署 FREEZE_SIGNOFF.yaml；冻结 12 个 CONF 任务，尤其要有真正的多标签任务；确认分割和预算。之后可以直接用 python scripts/run.py ––confirm 跑同一套机制（runner、fork、oracle 已在 DEV 上验证）。**若团队决定研究 F1**（属于新版本，需要重新冻结研究计划，不能写成 F0 的成绩），本 lane 的证据直接指向四个改动：（1）入口批准后对 target_spec 加写保护，每个 gate 与 C_read 比对；（2）fit 前校验 y 的列名和指纹是否等于 C_read；（3）序列化时校验输出列必须来自 predict()、禁止合成 ID，并用显式证据处理合法别名；（4）校验 ID↔预测配对摘要。同时应把入口的确定性重试直接改为 fatal，或让重试真正携带诊断信息。

证据链矩阵

主张	实验	表/图	最小复现命令	支持/限制/反例
入口 gate 改变错误动作（A–C1，入口）	A1、A2 (a)(b)	T–A1、T–A2、F–A1、F–A3	./reproduce.sh –– rebuild	DIRECTIONAL（DEV）；12/12 前缀为 S3；反例：Steel F01 理由错误
入口后 gate 改变错误动作（A–C1，入口后）	A1 F05/F10/B01、A2 (c)(d)	T–A2、F–A2	同上	NOT_SUPPORTED；12/12 前缀 F0 与 M3 终态相同
多阶段相对强入口检查有增量（A–C2）	A3	T–A3、F–A4	同上	NOT_SUPPORTED；作用域重合，12/12 一致
默认重试或定向修复保留更多正确交付（A–C3）	A2	T–A2	同上	NOT_SUPPORTED；S2 = 0；F0 比 M5 每对多 4 次调用
早期 gate 优于末端检查（A–C4）	A2	T–A2、F–A2	同上	(a) 方向有利（避免 6/6 错误 fit）；(c) 方向相反（M4 6/6 拦截，F0 0/6）
原稿 24/24 有效可复现	A0	T–A0a	同上	24/24 S1；标签域敏感性：Spaceship 交付的是概率
“No reviewer gates 0/4”是接口断裂	A0	T–A0b	同上	结局复现（0/2），耗时不复现