# RTS-MA-DS / TAI：负责人 A 独立实验任务书（可直接派发）

**专项任务：A：审计原稿门控是否真实约束训练/预测，完成同前缀局部因果干预。**

**共同协议：RTS-TAI-PARALLEL-v4.0；文档日期：2026-10-10；状态：PRE-FREEZE。** 此 PDF 完整包含四人共同协议、本人专项实验与共同交付要求，可离线独立阅读，不需要同时阅读其他三个 PDF。

**请先确认：** 原稿研究与既有 8 数据集来自用户提供的《Contract-Gated Multi-Agent Workflows for Localizing Target/Submission Drift in Automated Data Science》（稿件第 3–7 页）；12 CONF 和 4 TRANSFER 的具体 dataset ID、版本、SHA 和机器预算是**尚待团队签字的固定字段**，不可在签字前声称正式确认。实验“质量合格”“结果可用”“有利创新”是三件不同的事。

## 第一部分　四人共同且完全一致的公开／固定实验协议

### 1. 协议身份、适用范围与签字状态

本节是四份 PDF 的共同协议正文，内容和版本必须完全一致。项目代号 `RTS-TAI-PARALLEL-v4.0`，制定日期 2026-10-10，状态：**待签字冻结（PRE-FREEZE）**。它是一份可直接执行的研究任务规格，不表示 12 个新增数据集已经选定、代码已完成或实验已经通过。团队负责人须在正式 CONF 运行之前补全本协议第 11 节签字清单及任务登记信息，形成带 SHA256 的 `FREEZE_SIGNOFF.yaml`；每个人的结果包必须附同一份签字快照。

原稿研究的任务包为 `P=(q,D_train,D_test,S,H)`，契约为 `C=(Y,f,m,I,O,Σ_S)`：训练目标 Y、任务类型 f、指标 m、行标识 I、输出角色 O 和提交模式 Σ_S。它声称通过 `target_spec`、语义对齐与 `approved/retry/fatal` reviewer gate 减少语义漂移，重试预算每阶段最多 3 次。**论文中的 reviewer gate 与这里的科研实验质量门控是两种不同概念。**

原稿已经报告：8 个干净任务，各重复 3 次，补丁后 24/24 有效；16 个受损任务包中有 7 个提前拦截；消融 `No reviewer gates` 在干净任务上 0/4 完成。原稿还明确无独立 held-out test，外部框架以 3 次运行中最佳验证分数作排名。以上是“既有报告”，不能作为新增独立确认。正式实验不得在不核查代码的情况下假定旧版具备持续阶段语义核查、真实 `fit` 绑定或字段级定向修复。

四项工作相互独立：A 负责真实执行与局部因果；B 负责故障覆盖、合法变化和信息边界；C 负责端到端交付和资源收益；D 负责自然漂移和封存迁移。各组从同一个 `base_commit` 克隆，在自己的 `lane_X` 工作区运行；**任何人不能把另一位成员的新代码、数据或报告作为开工依赖**。最终汇合使用共同任务 ID、案例语义族、基线 ID 和日志格式，而非先后等待。

### 2. 数据集是“共享基础任务，不共享全部实验案例”

**DEV：8 个原稿任务，允许开发与调试。** 从原稿第 5 页任务清单建立只读注册条目：`Spaceship Titanic`、`Titanic`、`Bank Churn`、`Academic Success`、`Ghouls`、`Obesity Risk`、`Steel Plate Defect`、`House Prices`。它们已经用于旧稿，不得包装成全新 held-out 验证。`Steel Plate Defect` 在新协议里是否可作为**真正多标签**任务，须先根据标签共现结构和原始任务说明核验；若不符合，则保持原稿复现用途并修正分类，不得为凑类目强行贴标签。

**CONF：12 个新增基础任务，四类各 3 个。** 类目编号固定为 `CONF-BIN-01..03`（二分类）、`CONF-MC-01..03`（多分类）、`CONF-ML-01..03`（真正多标签）、`CONF-REG-01..03`（回归）。A/B/C 对这 12 个任务使用**相同的原始来源、文件版本、独立评估真值、数据划分、评分规范与 oracle 单元测试**，允许各 lane 独立开发 adapter，但须通过共同判分一致性单测；各自独立生成本工作流所需的故障/合法案例。D 的自然漂移实验也使用这 12 个未被注入故障的基础任务。相同任务产生多个变异或 seed，不能当成多个独立数据集。

**TRANSFER：另 4 个新增基础任务，四类各 1 个。** 编号 `TR-BIN-01`、`TR-MC-01`、`TR-ML-01`、`TR-REG-01`。仅 D 在冻结方法和迁移模板后开封；A/B/C 不得查看具体任务、封存故障或 D 的测试结果，也不得用它们修改规则。这 4 个任务在统计上也只代表 4 个独立基础任务，不能用数百次重复宣称广泛泛化。

**目前 12+4 的具体数据集名称、版本、许可、下载地址和哈希在先前稿件中未完成最终签字，本文不虚构它们已冻结。** 项目负责人须先完成数据注册与独立真值审查，四人才能启动正式 CONF／TRANSFER；四人可在此之前并行完成 DEV 代码和 pilot。冻结之前，16 个任务必须逐一落实以下编号，禁止让不同成员自行给同一个编号分配不同数据：

```
CONF-BIN-01 [具体数据待冻结]   CONF-BIN-02 [待冻结]   CONF-BIN-03 [待冻结]
CONF-MC-01  [具体数据待冻结]   CONF-MC-02  [待冻结]   CONF-MC-03  [待冻结]
CONF-ML-01  [具体数据待冻结]   CONF-ML-02  [待冻结]   CONF-ML-03  [待冻结]
CONF-REG-01 [具体数据待冻结]   CONF-REG-02 [待冻结]   CONF-REG-03 [待冻结]
TR-BIN-01   [封存名称]         TR-MC-01    [封存名称]
TR-ML-01    [封存名称]         TR-REG-01   [封存名称]
```

**访问权限明确分成两份：** `task_registry_public.csv` 对四人公开 DEV+CONF 的完整来源/真值/拆分（oracle 真值仍只能离线评估器读取），对于 TRANSFER 只公开 `TR_id`、任务族、`sealed_manifest_sha256`；`transfer_registry_sealed.csv` 保存 TR 的真正名称、来源、私有测试与故障细节，仅由协调人保管，D 在代码和模板冻结且签署开封记录后获得。A/B/C 直到确认论文主实验结束也不得查看 sealed 表。四份任务书和四份最终包共享同一个**公开注册表 SHA**，迁移密封登记只以 commitment SHA 校验，不要求全员提前读取它。数据选择遵循：来源可访问且许可允许研究；目标和指标有独立权威说明；可建立与训练隔离的私有测试；四类真实成立；没有与 DEV/彼此的同源任务重复；样本规模及可运行成本满足冻结预算。若同一原始来源拆成多个任务，`source_group_id` 相同，并按来源进行独立性审查。

完整注册表在有相应访问权限的视图中 **每行一个基础任务**，至少包含：`task_id`, `split_tier`, `source_group_id`, `source_name`, `source_url`, `license`, `original_version`, `source_sha256`, `task_family`, `target_columns`, `target_semantics`, `primary_metric`, `metric_direction`, `id_columns`, `output_columns`, `output_mapping`, `valid_aliases`, `data_split_policy`, `split_seed`, `split_hash`, `oracle_version`, `applicability_notes`, `owner_signed_at`。缺关键字段不得从 DEV 晋升为正式任务。原始数据若禁止再分发，仅保存合法的下载指令、哈希和固定索引，而不是擅自打包。

### 3. 数据划分、隐藏真值与统一的公开信息边界

同一个 CONF/TRANSFER 任务在所有适用方法和成员间必须使用相同 `split_id`、相同样本 ID 集与相同私有测试标签。优先采用经过确认的官方独立划分；否则在正式运行前固定约 `60% fit / 20% validation / 20% private test`。分组数据按 group，时序数据按时间，多标签数据用适当的多标签划分，避免同对象或未来信息泄漏。训练内交叉验证只能使用 fit 部分；validation 用于事先定义的模型选择；private test 只能在离线评价器中读取。必须存储索引清单与哈希。

项目共同采用数据划分起始随机数 `1729`；实际拆分实现、库版本和每个任务的 `split_hash` 应成为冻结文件的一部分。开发随机块 `1101,1102`，正式确认随机块 `2101,2102,2103`，迁移随机块 `3101,3102,3103`。相同 seed 只是配对设计；云端 LLM 即便 seed 相同也可能不确定，必须记录真实模型 ID、参数、响应和操作时间（遵守服务使用条款及脱敏要求）。运行顺序在每个随机块内随机打散并记录，避免全部方法总按固定顺序运行。

私有 `C_gold` 是评估器持有的真实任务契约，不能传给 agent；`C_read` 是 agent 入口实际解析出的契约；`C_used` 是真实训练/预测动作消费的语义契约。必须分别存储。`oracle_gold/`、`private_test_labels/` 和 agent 工作目录须隔离；任何通过 prompt、工具上下文、日志提示、缓存或模型选择把隐藏真值提供给受测 agent 的案例均视为污染，主结果无效。若任务可见材料本身不足以唯一识别目标，应标记“需要澄清/不可辨识”，而非硬把隐藏答案当作 agent 应当猜中的真值。

**信息可辨识层级固定：** `I-A`＝从可见材料可判定唯一任务；`I-B`＝信息冲突、需要权威证据/澄清；`I-C`＝相同可见材料与两个不同真实意图兼容、原理上不可唯一判定。`I-C` 不能纳入“可检测故障召回”的分母；其适当行为是谨慎澄清/停止，而不是读取评估器私有答案。合法别名、合法类别映射及语义保持变换必须作为独立的干净负例。

### 4. 案例及故障模板固定，允许成员独立实现

共享案例**语义编码**如下，定义的是要测试的现象，而非全组共享同一个故障脚本。具体变异参数、注入实现和数据对象由各组独立实现并预注册。

- C00：原始干净任务。
- B01：输出列有明确合法别名/映射；B02：不改变对象的列顺序变化；B03：明确指定且可逆的类别顺序/目标变换；B04：无关提示/特征的措辞变化。这四类为**合法变化**，不应因字面不一致而被误拦。
- F01：训练目标缺失；F02：目标不应存在却泄漏到供预测的数据；F03：结构合法但目标提示误导；F04：输出集合与真实任务不一致；F05：入口后真实训练目标漂移；F06：任务类型漂移；F07：主指标/优化方向漂移；F08：类别概率顺序或逆变换错位；F09：ID 与预测角色混淆；F10：ID 集合及输出尺寸不变、但预测与 ID 行配对被置换。
- P01：目标提示与输出目标的复合冲突；P02：中间阶段漂移加输出语义漂移，必须检查全部真根因。
- A01：显性证据冲突且无法权威决定；A02：相同可见证据支持两种不同目标意图，属于不可辨识边界。
- I01：dtype/值域等完整性破坏；I02：必需特征/训练测试模式破坏。它们是扩展 I/O 范围，需与核心目标/提交语义分层报告。

每个正式 case_manifest 至少记录：case_id，task_id，template_id，condition，injection_stage，base_sha256，changed_paths，mutation_sha256，visible_evidence_hash，C_gold_version，truth_status，information_level，recoverable，expected_safe_action，target_fault_fields，expected_detection_stage，applicability，pre_registered_exclusion_reason。故障必须能够通过独立脚本验证**真的生效**；合法变化须有语义等价证明。一个案例因不适用而放弃，必须在看到模型结果前标 N/A + 原因；不得凭方法表现再挑案例。F02 人工测试泄漏不得把私有测试真实标签放入 agent 可见环境。

### 5. 四人共用的版本与对照方法字典

以下 ID 和定义只能在全体签字后版本化调整；**不可用同一个方法 ID 代指两个不同实现**。

- F0_ORIGINAL：从原稿真实代码 SHA 复现的完整 RTS-MA-DS，保留它**原有**的契约核查、reviewer 和默认 retry；只读 hook 通过行为等价 smoke 才可称为 F0。若旧代码不可取得或重现，标 not_reproducible，不得用自行实现版冒称原稿。
- F1_EXTENDED：在 F0 之上**实际增加**的新能力，例如真实 fit 绑定、后续执行检查、字段级定向修复、I/O 合同；每项要独立列出开关和提交 SHA，只能作为新版本研究，不能把其结果写成原论文旧系统成绩。F1 是可选增强，不是四人的硬依赖。
- M0_NO_SEMANTIC_ENFORCEMENT：reader、必要状态更新、正常路由与安全/资源限制不变，只取消研究性的任务语义阻断；关门控不允许把系统弄崩。
- M1_STRUCTURAL_STRONG：字段存在性、类型、shape、ID 合规等强结构规则；不得暗读真实意图。
- M2_INTAKE_ONLY_STRONG：**与对应 Full 使用相同入口 reader、初始语义规则和冻结契约**，只在入口实施语义检查，后续不做该语义持续核查；这是证明“多阶段增量”的核心强基线。
- M3_SHADOW：持续计算相同 reviewer 检查并私下记判决，但其判决**不改变执行、不额外透露诊断**给 agent。
- M4_END_ONLY：保留真实动作轨迹，在末端按事先声明的规则检查，可按相同预算执行末端补救，用于检验提前检查的时机价值。
- M5_BLOCK_ONLY：相关阶段执行同样的判决约束，发现违规即阻断，不提供定向修复，以区分“规避错误”和“完成任务”。
- G_GENERIC_RETRY：与拟比较的定向修复方法匹配次数、时间和模型调用预算，但没有字段级诊断信息；仅在存在实际定向修复实现时用于恢复归因。

**主验证优先顺序：** 确认“原稿方法”时主对比 F0_ORIGINAL vs M2_INTAKE_ONLY_STRONG；检验判决是否真实改变动作时用 F0 vs M3；若 F1 才具备运行中语义约束或定向修复，则 F1 vs M2/G 的结果是**新版方法**的贡献，不得反写为 F0。若代码检查证明 F0 与 M2 的入口后检查实际上相同，必须记录这一定义上的重合，不能制造虚假差异。

同一可比较对照的 agent 可见包、LLM/搜索后端、prompt 主体、预算、基础训练器、方法初始化、split 和 seed block 应尽可能相同；有不可能消除的框架固有差异时标为**系统级比较**，不能把差异归因于单个 gate。安全沙箱从不关闭。所有补丁必须先通过 `version_diff.csv` 和只读 hook 行为等价检验。

### 6. 预算、随机化、运行停止和重跑规则

保留原稿每阶段最多 3 次重试这一已报告设定，但明确 `retries` 与 `attempts` 的计数语义，并在代码中加断言。**任务级墙钟时间、模型调用/Token 上限、CPU/GPU/并发数、预算不等价时如何归一化**在冻结前填写到 `frozen_config.yaml`；先允许用 DEV pilot 测量耗时，不允许先看 CONF 结果再调整预算。强对照必须在同一剩余预算和同等可见证据下比较；字段级修复与普通重试的次数上限一致。

一个随机块是相同任务、案例、数据拆分、配置的配对标识，不代表两个独立数据集。原始 LLM 输出或行为变化必须落日志。若调用 API 失败或 GPU 不可用，先保留原运行的 `S8` 与错误日志；是否可重试、重试次数和重试后结果如何合并按预冻结规则执行，**不能重跑到得到有利结果为止**。不因中期效果不显著而随意加 seed，也不因结果好就提前停止确认。预设安全故障（例如泄露测试标签）可立即中止涉及的批次，并将受污染案例标识为不可用于确认。

默认各角色共用一个小型 DEV smoke／pilot 任务池：四类任务各 1 个，两个开发随机块；每位负责人依自己方法做必要 smoke，而非要求所有成员重复完全相同的大型 pilot。预实验只校验可执行性、案例真值、成本估计与观测完整性；**不会因为 F0 在 pilot 中不优于基线而判 pilot 失败**。

### 7. 唯一的八类最终结局与计量口径

每次实际启动的运行必须有且仅有一个互斥终态（没有启动的 `N/A` 不属于 S1–S8）：

1. `S1 DIRECT_CORRECT`：未发生真实修复，训练对象/指标/行对应与真值一致，输出有效。
2. `S2 REPAIRED_CORRECT`：至少发生一次实际修复，最终语义正确且输出有效。
3. `S3 JUSTIFIED_STOP_OR_CLARIFY`：依据可见信息确实不能安全继续，合理拒绝或澄清。
4. `S4 UNNECESSARY_ABORT`：原任务可解却被错误拒绝或合法变换被错误拦截。
5. `S5 SILENT_SEMANTIC_ERROR`：生成**看似有效**的预测文件，实际目标、指标、类别、变换或 `ID→预测` 关系不符真实任务。
6. `S6 INVALID_ARTIFACT`：提交格式/列/行/数值等明确交付条件不满足。
7. `S7 VISIBLE_EXECUTION_FAILURE`：工具或代码可见异常，未发生 S5 语义有效外观的错误交付。
8. `S8 BUDGET_OR_INFRA_FAILURE`：预算终止或 API/硬件中断，必须记录 `budget` 或 `infrastructure` 子原因。

优先处理同一次运行中的混合事件：若已生成并**正式交付**有效外观但语义错误的文件，主终态为 S5；若没有有效交付而崩溃则 S7；资源故障阻断判定时 S8；其他过程中出现的错误还可写在事件序列，不能偷偷出现两个终态。模棱两可的案例须由离线 oracle 裁定并留存异议记录。

主指标全部采用**实际启动运行数**作分母，另行给出所有计划格及 `N/A`：`correct_delivery=(S1+S2)/N_started`；`silent_error=S5/N_started`；`unnecessary_abort=S4/N_started`；`justified_stop=S3/N_started`。故障检测的 `TP/FN` 分母只包含事前标为可辨识且适用的真故障；合法误拦 `FP/TN` 分母只包含事前确认的合法场景；根因定位要另报 `exact_match`、部分匹配和无定位。正确停止不等于成功交付；发现“早停”不等于发现正确字段。

预测指标只在**语义正确且提交有效**的运行中报告，再同时给出“以全部启动为分母的正确任务交付率”；AUC、macro-F1、RMSE 不混合平均。资源报告：真实墙钟秒、错误目标 `fit` 训练秒、所有 API 调用数、确有可靠采集时的输入/输出 tokens 和收费；`每次正确交付成本 = 该方法全部启动运行的总成本 / (S1+S2 次数)`，成功次数为 0 时记 **undefined**，不能记 0。提前停止节省了错误训练时间也不能单独证明总体效率更好。

### 8. 统一统计计划及“有利创新”的预先定义

主统计单位是独立基础任务/独立数据来源，主配对键至少为 `(task_id, case_family, seed_block, host_id, model_id)`；因果同前缀实验还必须有**相同分叉前快照与候选动作哈希**。对每任务先汇总配对差，再给任务级均值、任务聚类 95% 区间、逐任务方向和留一任务敏感性；若多个任务来自同一源，需要更高层级

source_group_id 聚类。少量任务时区间本身也不稳，必须诚实表述。二项零事件要有适当上界，不能拿“0/24”宣称真实风险为零。

主方向预先定为 F0 相对 M2 的静默语义错误率减少，同时检查是否增加 S4、是否损害 S1+S2，以及成本。若 F0 逻辑等同 M2，则该主张无法由旧方法获得支持；只有明确新增机制并重新冻结研究计划，才能以 F1 建立新版主张。A 的 F0 vs M3 对动作层有效性是必要但不充分证据；C 的 F0 vs M2 对最终交付是核心；B 与 D 分别提供判定边界和外部有效性。

建议在 DEV 上预设两个**研究实用性容忍参考值**：合法/干净条件的正确交付率相对强基线损失不超过 5 个百分点，每正确交付成本相对增加不超过 20%。它们须经团队签字方可生效，**不是 TAI 官方门槛**，也不意味着 12 个任务足以作严格非劣效性证明。若置信区间不足以排除超过容忍界限的损失，应写“未排除有害权衡”，不能拿点估计替代非劣效检验。

四种结论必须区分：QC_PASS＝实验技术上合格；RESULT_USABLE＝对预先问题有可信、可复核的估计（包括负结果）；CLAIM_SUPPORTED_STRONG＝预设主对比呈有利方向且任务级 95% 区间与容忍权衡允许强措辞；CLAIM_DIRECTIONAL / NOT_SUPPORTED / INDETERMINATE＝仅趋势、结果反向或证据不足。**质量门控不会被设计成“Full 必须好于阈值才算过”。** 仅统计效果方向有利但区间跨 0，属于可报告的初步信号，不是统计确证。论文需报告所有预定比较，多重确认检验须在冻结计划中定义调整方案。

### 9. 通用科研实验质量门控：G0–G6

这些门控是**实验是否值得写入论文**的资格条件，不是算法自己的阻断规则；四人都要在 quality_gates.csv 中逐实验填写 PASS/FAIL/NA、证据文件、确认者和时间。

- G0 协议签字：FREEZE_SIGNOFF.yaml 存在，CONF 12 个任务的完整公开登记、TRANSFER 4 个任务的封存登记哈希、每项任务的拆分、base SHA、方法版本、预算、主指标、确认比较、seed、排除/重跑政策冻结；未签字只能做 DEV，不能声称 CONF 完成。
- G1 真值和案例：所有进入主分析的任务目标、适用性、合法等价或故障生效经独立单元测试验证；隐藏标签/答案与 agent 隔离；每个变更可回溯到唯一变异器及 hash；任何有污染的案例隔离，不用于主分析。
- G2 对照可运行：每个本组实际用到的方法通过 DEV smoke；至少两个干净 DEV 任务下基础工作流能正常到达有效终态。特别禁止把“关闭 reviewer 导致接口断裂”当作方法改善；需要真实阶段动作的实验必须证明 instrument/hook 工作。
- G3 运行账本闭合：每个计划格记 completed/N/A/not_started/infra_failed 等状态；每个实际启动必须落 S1–S8 之一、唯一 run_id 与原始日志；**100% 启动运行可追溯**。关键动作缺失只能单列“该动作指标不可判”，不能静默把该运行从主分母删掉。
- G4 比较与污染检查：同一配对的输入、split、seed、可见证据、预算和版本严格匹配或列出不可比较原因；同前缀因果实验分叉前状态和候选动作 hash 必须相同；private test 无泄漏；差异无法归因门控时不得称为局部因果证明。
- G5 统计与可再现：完整计划格或明确“部分矩阵”；可用冻结环境从**原始日志**重建逐次、逐任务结果及每张表图；人工核对至少 2 个有利和 2 个不利/失败记录（若没有有利例，核对全部失败/空事件），数值分子/分母一致。禁用挑最好 seed、偷偷重跑、事后换类别。
- G6 主张匹配：完成每个实验的 QC / USABLE / SUPPORT 三份独立判定，明确独立统计单位、置信区间、反例与适用范围；不因结果不利判实验失败，也不把故障注入比例当自然发生率。

在某个实验的 G0–G5 实施条件失败时，标 QC_FAIL 并说明污染范围；若只是效果不符合预期但技术条件通过，应标 QC_PASS, RESULT_USABLE, CLAIM_NOT_SUPPORTED。若完整矩阵未跑完，只能写“部分结果”，不能暗中用预定总数作分母。代码修复须另记版本、新的实验批次与首次发现日期，不能覆盖原日志。

### 10. 统一的计划规模、避免重复计算和并行协调

四人**共享基础任务，不共享方法成绩**，按各自工作负载独立执行：A 计划 144 个相同前缀、最多 720 条干预续跑和 72 条入口检查分支；B 在 12 个 CONF 上最多 252 个语义案例，最多 1764 次轻量判定；C 计划

12×5×4×3＝720 次端到端完整运行；D 的自然观察 12×2×3＝72 次、迁移 4×2×2×3×3×3＝432 次。上述数字是**计划上限/参考量**，不是当前完成数、也不是期刊硬规定；各自的 N/A 和不支持情况需依冻结协议报告。A 的续跑不是 720 个独立基础任务；B 的“判定调用”不是 1764 次完整训练；D 的 432 次仍只涉及 4 个封存基础任务。

开工分工：**项目协调人（可由作者本人担任）**唯一负责发布冻结的只读数据/协议快照、封存目录权限及合并后的事实核查，不需要替任一成员写代码或跑实验；A/B/C/D 各自配置运行器、变异器、离线 oracle、报告程序。成员可以提前在 DEV 做小规模独立开发；在 CONF/TRANSFER 的相应门控满足后直接运行自己路线。个人结果不得通过共享 PR 改动其他人的实验结果；真正需要的共享接口应在本人的 adapter 中完成并记录偏差。

每周只同步“协议问题、复现阻断和资源占用”，**不讨论 CONF 中途哪种方法赢、哪些任务对 Full 有利**。D 的 TRANSFER 目录及模板 hash 要封存到迁移冻结节点。跨路线最后用同一 `task_id` 与语义故障族建立**证据索引**，不能假定 A 与 C 在同一 task 上的不同 run 是一个实际因果轨迹。

### 11. 四人共用的开工签字清单（需要在正式运行前真实填写）

1. 原始 RTS 代码仓库地址、`base_commit`、有无旧故障包、各方法适配实现责任人：[待填]。
2. CONF 12 个任务的**正式名称、来源、许可证、SHA、目标、指标及拆分 hash**：[待填，见 `task_registry_public.csv`]；TRANSFER 4 个任务由协调人对 `transfer_registry_sealed.csv` 完整签字，四人共同记录其 seal SHA，D 按规定开封。
3. 原稿 F0 对应实现开关、M2 是否存在与 F0 是否行为不同、F1 是否计划新增：[待填]。
4. 每次完整运行的墙钟/LLM 额度、机器配置、并发数、API 模型 ID、版本、温度、提供商限制：[待填]。
5. 稳健性分层、确认主效应、若启用 5pp/20% 容忍界限的批准签字：[待填]。
6. 公共文件全套 SHA256、签署时间、签署人、封存任务解封时间/责任人：[待填]。

**未填写不是“允许各自决定”，而是尚未具备正式 CONF/TRANSFER 研究的 G0 资格。** 每个人收到 PDF 后可以在 DEV 开工，但必须以签字快照替换其结果包中的所有 [待填]。

## 第二部分　负责人 A 专项：真实执行与局部因果作用

### A 的职责、独立性与需要回答的主要科学问题

A 必须独立验证：原稿所谓冻结 `target_spec` 是否被真实 `fit/predict/serialization` 消费；reviewer 决策是否实际改变执行路径；在同一个错误动作即将执行的前缀上，放行、阻断、普通重试、定向修复和末端检查各自引起什么差异。**A 不等 B 给故障包，也不依赖 C 的评测脚本；自己根据共同模板定义四种主要上下文与离线真值。**如果原稿 F0 仅有入口检查而没有持续动作绑定，须准确报告，而不能把 F1 补丁写成 F0 的实验成果。

A 的主要确认主张分成三层：`A-C1` 实际 gate 能改变错误动作（对 M3）；`A-C2` 若存在持续核查，则相对 M2 可防止入口之后的漂移；`A-C3` 若存在定向恢复能力，则能比仅阻断（M5）或一般重试（G）保留更多正确交付。三层只能依据各自具有的真实实现宣称。

### A0. 旧结果核对、无门控可运行性与代码语义审计

**实验设计。** 在八个 DEV 原稿任务上核对旧版 Full 与当前代码的一致性。可复现旧配置时，干净任务 8×3=24 次；原稿 16 个故障包逐一做对应回放。再对 M0 与 M3 做不少于 2 个干净任务的完整 smoke，并在 4 个任务族代表上分析 4 个探针：目标缺失、错误目标提示、合法输出别名、入口后目标替换。

**具体步骤。** (1) 固定源代码 SHA 与旧 config；(2) 搜索每个 reviewer 的输入、输出、状态写入和路由依赖；(3) 把“计算判决”和“执行判决”的代码路径分开；(4) 禁止删除 reviewer 所提供的必要状态/回调；(5) 收集 M0、M3、F0 的实际完成轨迹、异常栈与每阶段时间；(6) 对比原稿 Table 3 中关 gate 导致干净任务全部停止的原因，如果源码不足，明确“原因不可核验”，不填猜测结论。重点检查旧 Table 5 的缺训练目标 2/3 拦截与正文规则是否冲突，以及原稿不同时长统计的样本来源。

**A0 质量门控。** 必须拥有可识别的原稿版本或明确不可复现说明；F0、M0、M3 的实现差异可以按函数定位；最少 2 个 DEV 干净任务中 M0、M3 在不依赖语义 gate 的情况下走完整流程；四探针至少有正确哈希和 expected outcome。若 M0 因缺少正常状态字段而失败，立即 `A0-QC_FAIL`，此消融不进入机制结论。

**A0 结果可用。** 能回答旧数是否重现、差别是代码版本还是实验配置、无门控是否保留必需流程。发现旧消融不可解释也是可靠负面审计结果。

**A0 对创新有利的条件。** 在真实保持执行图完整的前提下，F0 的语义阻断确实使已注册错误探针改变下一动作；仅看到崩溃减少或平均耗时减少，不足以支持语义约束的因果价值。

**A0 交付。** `A0_old_vs_current.csv`、`A0_method_diff.md`、`A0_smoke.csv`、reviewer 状态/路由调用图的**纯文字事件列表**、用于论文的“旧结果和修正消融”对照表。

### A1. C_gold、C_read 与真实 fit/output 的绑定核查

**实验设计。** 从四种任务族各取 1 个 DEV 任务，每个设置六类探针：正常完成、合法别名、可修复冲突、不可修复缺目标、planner 后目标漂移、输出类别/ID 配对错位。每个探针分别走 F0 和 M3，默认 4×6×2=48 条开发轨迹；若真实调用不可拦截，记录 observability gap，不用假造 `actual_fit_target`。

**实施步骤。** (1) 用只读 hook 在 reader、reviewer、planner、实际 `fit` 调用、predict 和最终文件写入点写 `events.jsonl`；(2) 从实际张量源、目标列名及与行顺序绑定的 digest 核对训练目标，不信任 LLM 文本说明；(3) 对输出记录 `class_order`、inverse_transform、每一行的 ID 映射摘要；(4) 分开标注“reader 最初读错”“reader 正确但下一阶段改错”“状态正确但最终动作实际做错”；(5) 对不可能抓到的动作事件，报告覆盖比例和无法证明的边界。

**A1 质量门控。** 48 个计划格各有运行或预注册 N/A；每条声称“真实执行一致/不一致”的轨迹必须有 `C_read`、gate 判决及实际 `fit/predict` 事件，事件顺序与哈希一致；对输入探针的操作生效应由额外断言证实。若只拿 agent 回答来断言真实 `fit`，`A1-QC_FAIL`。

**A1 结果可用。** 能分别汇总初始契约错误、阶段漂移、实际消费脱钩、输出错配四种失败分母及各自来源事件，即使 F0 表现差也可用。

**A1 创新支持判断。** 只有 F0 所批准的契约能稳定约束真实训练和序列化（或者显式拦截漂移），才支持执行真实性。若原稿只保证共享字段被冻结、却允许真实模型使用别的 y，则原稿执行真实性主张不成立；若 F1 解决了，要独立报告 F1 新贡献。

**A1 论文产物。** `T-A1: 真值/入口/真实 fit/输出逐任务一致性表`；`F-A1: 来自真实 run_id 的动作链轨迹图`；附至少一个正例和一个不符合机制预期的逐事件实例。

### A2. 同一候选动作下的放行—阻断—恢复配对干预（主实验）

**正式配置。** 12 个 CONF 任务 × 4 类上下文 × 3 个确认随机块 = **144 个独立快照前缀**。四类上下文：(a) 可恢复的入口目标/提交冲突；(b) 不可恢复的目标缺失；(c) 入口正确但 planner 后 `fit` 标签改变；(d) 预测阶段 ID/类别角色错位。每个前缀最多执行 `M3_SHADOW`、`M5_BLOCK_ONLY`、`G_GENERIC_RETRY`、`F0_ORIGINAL`、`M4_END_ONLY` 五条后续分支，最多 **720 个续跑**。G 对没有定向诊断可比性的分支可在预注册时标 N/A；F1 若新增，必须单独增加计划格。

**实施步骤。** (1) 依共同任务注册，A 自己制作变异器，确保每次只在声明节点注入，保存前后 hash；(2) 执行到 gate 之前并冻结 `state_hash`、`candidate_hash`、`visible_evidence_hash`、`remaining_budget`、`rng_state`；(3) 复制五个隔离工作区并从**完全相同的候选动作**继续；(4) 只切换 gate 阻断权、末端位置或重试诊断模式；(5) 逐条记录 next action、实际错误 fit 是否发生、错误文件是否交付、S1–S8 终态、调用与成本；(6) 对没有严格共同前缀的配对，标为普通随机块比较、从主因果估计剔出但保留运行记录。

**主要比较。** `F0-M3`＝判决执行权对错误动作/静默错误的影响；`F0-M5`＝允许原稿默认 retry 后是否保留更多交付；`F0-M4`＝早期 gate 相对末端核查减少的错误训练是否抵消重试开销；若 F1 实现字段级修复，才计算 `F1-G`。每个主张既报阻断率也报 S4（误停止）、S5（静默错）与 S1+S2（正确交付），不能只报“停了多少”。

**A2 质量门控。** 144 个前缀都有状态且可归档；每个主因果配对前缀的 4 个 hash/预算核验一致，所声明的 gate 策略确实不同；**所有实际启动续跑均有互斥终态**，存在错误动作的场景均有真实 fit/交付事件；若注入不是唯一差异或分叉时随机状态失配，剔出主因果比较并说明样本减损原因。CONF 初始版本和修复后的版本不能混为一个确认批次。

**A2 结果可用。** 输出按基础任务和四个场景计算的“是否执行错误动作、静默错误率、正确交付率、误拦率、错误训练时间、总成本”配对差与任务聚类区间，且可定位每一对运行的共用候选动作。

**A2 对创新有利的结果。** F0 相比 M3 实际减少了错误执行/静默交付，主要效果任务级区间有利，且没有以大量 S4 换取表面上 S5 降低；若原稿没有真实阶段约束、只对入口故障有益，则必须缩小创新主张；若 F1 有效，另外给 F1 的效应而不替换 F0。

**论文表图。** T-A2：四类上下文×五种决策的动作与完整终态；F-A2：逐任务局部效应森林图（含区间）；F-A3：同一前缀五种后续动作轨迹（示意线条来自真实事件 ID）。

### A3. 强一次性语义检查是否已经足够?

**实验设计。** 利用 A2 两类前缀——入口冲突和后阶段目标漂移——增加 M2_INTAKE_ONLY_STRONG 分支：12×2×3=**72 条续跑**，与相应 F0 的快照配对。入口语义规则、reader、训练器和预算完全相同，**唯一研究性差异**是入口之后是否持续验证/阻断。

**A3 质量门控。** 断言 M2 没有偷偷看到下一阶段的私有故障真值；两方法的入口判决轨迹一致；若代码查明 F0 并无后续语义核查，标为“F0 与 M2 方法作用域重合”，不要构造无法复核的差异。

**A3 结果可用。** 给出 F0-M2 按入口/后阶段的配对差、区间、对照定义是否成立及其代码证据；零效果也是可用发现。

**A3 有利创新。** 对**入口之后产生**的语义漂移，F0 比 M2 更少执行错误目标或错配输出，并保留正常任务完成；如果只有 F1 明显改善，只能支持新增持续核查机制，而非原稿已经具有的贡献。

**论文产物。** T-A3：入口一次性检查 vs 原稿完整机制；F-A4：故障发生位置×两组增量效果；A_claim_ledger.md 列明每个主张支持、反例、无法观察的边界。

### A 的独立结束与最短交付检查

最终提交 lane_A_final.zip、lane_A_evidence_report.pdf；至少含 A0–A3 全部计划格、原始分叉快照与事件、独立变异器、有效的关 gate 实现、4 张主表图、F0/M2 源码比较及所有负面案例。结论首页分别回答：**F0 的行为约束真实存在吗？错误动作实际改变了吗？与强 M2 有什么增量？是否只是更多拒绝？哪些判断没有可靠观察条件?**

## 第三部分　四人共同且完全一致的代码、数据、结果与论文交付标准

### 1. 最终到底交什么给项目负责人?

每位负责人最终提交两件物品：lane_X_final.zip（X 为 A/B/C/D；可复现实验包）和 lane_X_evidence_report.pdf（建议 4–8 页**普通文字＋必要统计图表**的结果解释）。实验包中必须同时包含可运行代码、原始证据、全部计划格索引、统计脚本、结果表图和失败/反例。只给汇总 Excel、截图、几条精简日志或论文措辞，**不算通过交付验收**。TXT/MD 源文档可作为辅助，但不能替代机器可读的主记录。

目录及文件名必须遵循共同协议，以便在不等其他人代码的情况下独立打开与重建：

```
lane_X_final/
  README.md                 # 一页运行说明、研究问题、完成率、主要发现
  BASE_COMMIT.txt           # 原稿 SHA、本分支 SHA、方法哈希
  FREEZE_SIGNOFF.yaml       # 四人完全相同的签字冻结协议快照
  CHANGELOG.md              # F0 / 只读观测 / F1 的版本差异
  SHA256SUMS                # 案例、配置、日志和表图的哈希索引
  protocol/
    PROTOCOL.md             # 与四份 PDF 的共同协议同版
```

```
  task_registry_public.csv # DEV/CONF 完整信息；TR 仅 ID 与密封哈希
  split_registry.csv       # 来源、拆分和隐藏测试 hash
  frozen_config.yaml      # 模型、预算、依赖、seed、温度、硬件
  methods.yaml             # 方法 ID 与真实实现开关
  outcomes.yaml            # S1-S8 与判分优先级
  analysis_plan.md         # 预注册主指标、对比、CI、N/A 规则
  deviations.csv           # 冻结后所有变动/例外及时间
env/
  environment.lock         # requirements.lock / conda.lock / 镜像摘要
  runtime_info.json        # OS、CPU/GPU、服务模型真实 ID
src/
  adapters/                # 自己路线实现，独立于其他 lane
  oracle/                  # 离线判分器，运行时与 agent 物理隔离
cases/
  manifest.csv             # 每个基础任务和案例、适用性、故障真值
  mutation_specs/          # 有版本/哈希的变异器参数与脚本
scripts/
  smoke.py                 # 最小检查，能自动输出门控结果
  run.py                   # --dry-run / --pilot / --confirm / --resume
  evaluate.py              # 独立 oracle，八种终态与正确任务评分
  analyze.py               # 任务级配对统计、CI 与敏感性
  make_paper_assets.py     # 从原始记录重建全部论文表图
logs/
  plan_ledger.csv          # 包括未启动/N/A 的全矩阵
  run_index.csv            # 唯一 run_id、路径、SHA、状态
  events/*.jsonl           # 每次运行的真实判决/动作/模型/交付事件
  errors/                  # API/工具/硬件错误、失败重试和回溯
outputs/
  artifact_index.csv       # 产物 hash、判分、缺失/无效原因
results/
  run_level.csv            # 一启动一行，失败不得删
  pair_level.csv           # 同任务/同前缀可比性键
  task_level.csv           # 独立任务级效果、区间和方向
  resource_ledger.csv      # 时间、调用、训练浪费、缺失计量
  quality_gates.csv        # G0–G6 + 本 lane 每实验门控
  claims.csv               # QC/USABLE/SUPPORT 的三层结论
paper/
  tables/*.csv             # 正文/附录每张表的数字及分母
  figures/*.pdf            # 简洁黑白论文图，由脚本生成
  figures/*.png            # 查阅预览
  cases/*.md               # 正例、反例、无效例及事件 ID
  evidence_report.pdf      # 本人成果的可写作结论与局限
reproduce.sh               # 只使用本目录与合法外部数据来源
```

task_registry_public.csv 只包含 A/B/C 可见的 DEV/CONF 细节与 TRANSFER 封存哈希；A/B/C 不得提前得到 TRANSFER 名称、私有标签或故障内容。D 的有权限私有副本应在封存开封后单独归档。若有关文件因版权/API 许可不能入 ZIP，应交**非敏感引用索引、合法获取命令、哈希和权限说明**，并在 README 中明确是否可完全公开复现。密钥只能通过环境变量读取，禁止打包 API Key、测试标签明文或匿名投稿受限文稿。

### 2. 所有 lane 的最少日志字段：必须逐行可连接

plan_ledger.csv：plan_cell_id, lane_id, stage, task_id, source_group_id, condition, template_id, case_id, method_id, host_id, model_id, seed_block, planned_status, applicability, n_a_reason, freeze_sha。每个计划格都在运行前生成，执行后更新状态；主论文标明实际启动数、完成数、N/A、未运行数，不可把 N/A 记为失败率分母中的 0。

run_level.csv：run_id, plan_cell_id, pair_id, task_id, source_group_id, case_id, case_family, method_id, implementation_sha, split_hash, oracle_version, prompt_sha, config_sha, seed_block, host_id, model_id, started_at, finished_at, terminal_S, terminal_subreason, semantic_correct, artifact_valid, actual_fit_target_hash, actual_metric, output_mapping_valid, rejected_valid_case, wall_seconds, wrong_training_seconds, api_calls, tokens_in_if_observed, tokens_out_if_observed, measured_cost_if_observed, artifact_sha256, event_trace_path, exception_path, missingness_reason。确实无法观测的字段必须写 NA 及原因，不能写 0；不能靠 agent 自评来填 semantic_correct。

events.jsonl：每条至少含 event_id，run_id，monotonic_seq，timestamp，phase，actor，event_type，state_hash，candidate_hash，contract_digest，source_fields，verdict，next_action，actual_fit_target_hash，artifact_mapping_digest，error_subtype。应能从 reviewer 判决追到真实 fit/predict 或合理停止，且顺序单调。可复核性最好提供至少一条正向和一条反向的完整轨迹索引。

quality_gates.csv：experiment_id，gate_id，status，checked_count，eligible_count，evidence_path，reason，checked_by，checked_at。claims.csv：claim_id，experiment_id，primary_contrast，estimand，units，estimate，ci_low，ci_high，qc_status，result_usable，support_level，counterexample_ids，allowed_paper_wording。任何论文中的“改善百分比”都应能返回这些记录核验。

### 3. 代码提交最低验收：不靠作者口述即可运行

1. ./reproduce.sh --smoke 从干净环境加载冻结配置并完成最小测试；需要外部私有数据时明确 DATA_ROOT 与下载授权，不能偷偷使用作者本机绝对路径。
2. python scripts/run.py --dry-run 打印实际矩阵、计划数、N/A 和成本预估；--pilot 与 --confirm 分阶段运行，--resume 能以唯一 run_id 恢复，绝不覆盖已存在的完成日志。
3. 同一个源文件只做一次 SHA256 登记；环境/接口变更带新 implementation_sha，所有无门控、shadow 和检查变体能够通过配置独立运行，不能修改共享源文件“硬切换”后丢失版本。
4. python scripts/evaluate.py 离线读取 oracle/私有测试，不依赖 agent 主观自述；对八终态、输出行映射、误拦、预算失败均有固定单元测试。
5. python scripts/analyze.py 由全部启动运行生成分母和配对统计；python scripts/make_paper_assets.py 自动重建每张表/图，并保存图表至运行文件及统计单位的溯源索引。
6. 除必要第三方外，不允许依赖 ../lane_A、../lane_B、../lane_C、../lane_D 等别人的私有目录。若发现不可移植，提交前调整为自己的 adapter 或经签字公开的共同 package。

以上命令是**交付时要求成员真实实现并测试的接口规范**，不是声称当前已有可以直接执行的脚本。

### 4. 什么程度的记录足以用来撰写 TAI 论文?

**Methods:** 可以精确定义 F0 的契约、检查频率、路由权、失败语义和可观察动作；若实际实现不同于论文伪代码，能用代码差异与完整版本审计说明。要有 F0 对照、强 M2 的算法/接口差别，不用代理文字叙述代替源码。

**Experimental setup:** 每个任务有来源、目标、私有测试隔离证明、分层和独立性；每个故障有代码、可恢复性、正确响应/字段与可见信息；每个方法有真实预算和输入；所有不支持格子、技术故障和除外规则可公开复核。

**Main results:** 每一个主效应都有完整分母、独立任务数、置信区间、逐任务差、比较方法、三类完整终态风险（静默错、正确交付、误拦），不采用 best-of-three 或只统计“能写出文件”的系统。若 12 个任务得不出精确结论，可以如实报告不确定性，并考虑预先注册的独立扩展，而不是复制 seed 增加名义样本数。

**Mechanism evidence:** 事件轨迹能从 C_read 到真实 fit/提交映射，再到 gate 决策和分叉后结局；至少一个可核对的正向案例及一个不支持该主张的反例（若真实不存在正向案例，说明不存在，不得捏造）。同前缀比较还提供状态与候选动作 hash。

**Boundary and transfer:** 故障覆盖须报告“合法变体误拦”与不可判定问题；自然漂移须说明注入与非注入区别；迁移须报告两个宿主、两个模型家族和未见模板在每个单元的真实运行情况、失效组合和精度限制。

**Paper assets:** 每张图/表有文件源、生成命令、归一化方式、配对层级和引用的原始运行索引；正文不要出现源文件里无法核验的新数字。给出一份“证据链矩阵”：主张 → lane → 实验 ID → 表图编号 → 最小复现命令 → 支持/限制/反例。

**5. 负责人最终怎样验收四个实验包?**

- **交付合格（PACKAGE_PASS）**：压缩包结构、冻结快照、原始日志、失败记录、重现脚本、图表都齐全；能在清洁环境完成 smoke，并重建本人的主要表格。否则退回补齐，即使图表方向很有利也不算完成。
- **结果可用（RESULT_USABLE）**：基础任务独立性、案例真值、对照公平、终态完整、配对估计和不确定性符合本 lane 的问题；负结果同样可能可用。若数据污染、对照失效、哈希不匹配或主分析没有完整分母，应标 `NOT_USABLE` 并说明需重跑哪部分。
- **创新支持（CLAIM_SUPPORTED）**：A 证明动作层因果，B 证明语义边界的额外检测价值，C 证明端到端静默错误减少并保留正确交付，D 给出自然问题证据/真实封存迁移。四项共同支持**有条件的、证据可跟踪的** TAI 主线；单项漂亮结果不能替代其他环节，负结果可能导致主张收窄或方法升级。

论文最终总结时，还必须给四条证据链之间的**一致性审计**：相同语义故障在 A 的动作差、B 的定位差、C 的终态差是否方向兼容；若不兼容说明原因，不要把不同成员不相干的 run 硬拼成一条实际因果样本。是否达到 TAI 的发表水平还取决于方法原创性、相关工作定位及证据规模，**门控通过并非期刊接受保证**。