RTS-MA-DS / TAI：负责人 B 独立实验任务书（可直接派发）

专项任务：B：构造有真值的语义故障与合法对照，测定覆盖率、误拦率与可判定边界。

共同协议：RTS-TAI-PARALLEL-v4.0；文档日期：2026-10-10；状态：PRE-FREEZE。 此 PDF 完整包含四人共同协议、本人专项实验与共同交付要求，可离线独立阅读，不需要同时阅读其他三个 PDF。

请先确认： 原稿研究与既有 8 数据集来自用户提供的《Contract-Gated Multi-Agent Workflows for Localizing Target/Submission Drift in Automated Data Science》（稿件第 3–7 页）；12 CONF 和 4 TRANSFER 的具体 dataset ID、版本、SHA 和机器预算是**尚待团队签字的固定字段**，不可在签字前声称正式确认。实验“质量合格”“结果可用”“有利创新”是三件不同的事。

第一部分　四人共同且完全一致的公开／固定实验协议

1. 协议身份、适用范围与签字状态

本节是四份 PDF 的共同协议正文，内容和版本必须完全一致。项目代号 `RTS-TAI-PARALLEL-v4.0`，制定日期 2026-10-10，状态：**待签字冻结（PRE-FREEZE）**。它是一份可直接执行的研究任务规格，不表示 12 个新增数据集已经选定、代码已完成或实验已经通过。团队负责人须在正式 CONF 运行之前补全本协议第 11 节签字清单及任务登记信息，形成带 SHA256 的 `FREEZE_SIGNOFF.yaml`；每个人的结果包必须附同一份签字快照。

原稿研究的任务包为 `P=(q,D_train,D_test,S,H)`，契约为 `C=(Y,f,m,I,O,Σ_S)`：训练目标 Y、任务类型 f、指标 m、行标识 I、输出角色 O 和提交模式 Σ_S。它声称通过 `target_spec`、语义对齐与 `approved/retry/fatal` reviewer gate 减少语义漂移，重试预算每阶段最多 3 次。**论文中的 reviewer gate 与这里的科研实验质量门控是两种不同概念。**

原稿已经报告：8 个干净任务，各重复 3 次，补丁后 24/24 有效；16 个受损任务包中有 7 个提前拦截；消融 `No reviewer gates` 在干净任务上 0/4 完成。原稿还明确无独立 held-out test，外部框架以 3 次运行中最佳验证分数作排名。以上是“既有报告”，不能作为新增独立确认。正式实验不得在不核查代码的情况下假定旧版具备持续阶段语义核查、真实 `fit` 绑定或字段级定向修复。

四项工作相互独立：A 负责真实执行与局部因果；B 负责故障覆盖、合法变化和信息边界；C 负责端到端交付和资源收益；D 负责自然漂移和封存迁移。各组从同一个 `base_commit` 克隆，在自己的 `lane_X` 工作区运行；**任何人不能把另一位成员的新代码、数据或报告作为开工依赖**。最终汇合使用共同任务 ID、案例语义族、基线 ID 和日志格式，而非先后等待。

2. 数据集是“共享基础任务，不共享全部实验案例”

DEV：8 个原稿任务，允许开发与调试。 从原稿第 5 页任务清单建立只读注册条目：`Spaceship Titanic`、`Titanic`、`Bank Churn`、`Academic Success`、`Ghouls`、`Obesity Risk`、`Steel Plate Defect`、`House Prices`。它们已经用于旧稿，不得包装成全新 held-out 验证。`Steel Plate Defect` 在新协议里是否可作为**真正多标签**任务，须先根据标签共现结构和原始任务说明核验；若不符合，则保持原稿复现用途并修正分类，不得为凑类目强行贴标签。

CONF：12 个新增基础任务，四类各 3 个。 类目编号固定为 `CONF-BIN-01..03`（二分类）、`CONF-MC-01..03`（多分类）、`CONF-ML-01..03`（真正多标签）、`CONF-REG-01..03`（回归）。A/B/C 对这 12 个任务使用**相同的原始来源、文件版本、独立评估真值、数据划分、评分规范与 oracle 单元测试**，允许各 lane 独立开发 adapter，但须通过共同判分一致性单测；各自独立生成本工作流所需的故障/合法案例。D 的自然漂移实验也使用这 12 个未被注入故障的基础任务。相同任务产生多个变异或 seed，不能当成多个独立数据集。

TRANSFER：另 4 个新增基础任务，四类各 1 个。 编号 `TR-BIN-01`、`TR-MC-01`、`TR-ML-01`、`TR-REG-01`。仅 D 在冻结方法和迁移模板后开封；A/B/C 不得查看具体任务、封存故障或 D 的测试结果，也不得用它们修改规则。这 4 个任务在统计上也只代表 4 个独立基础任务，不能用数百次重复宣称广泛泛化。

目前 12+4 的具体数据集名称、版本、许可、下载地址和哈希在先前稿件中未完成最终签字，本文不虚构它们已冻结。 项目负责人须先完成数据注册与独立真值审查，四人才能启动正式 CONF／TRANSFER；四人可在此之前并行完成 DEV 代码和 pilot。冻结之前，16 个任务必须逐一落实以下编号，禁止让不同成员自行给同一个编号分配不同数据：

```
CONF-BIN-01 [具体数据待冻结]   CONF-BIN-02 [待冻结]   CONF-BIN-03 [待冻结]
CONF-MC-01  [具体数据待冻结]   CONF-MC-02  [待冻结]   CONF-MC-03  [待冻结]
CONF-ML-01  [具体数据待冻结]   CONF-ML-02  [待冻结]   CONF-ML-03  [待冻结]
CONF-REG-01 [具体数据待冻结]   CONF-REG-02 [待冻结]   CONF-REG-03 [待冻结]
TR-BIN-01   [封存名称]         TR-MC-01    [封存名称]
TR-ML-01    [封存名称]         TR-REG-01   [封存名称]
```

访问权限明确分成两份： `task_registry_public.csv` 对四人公开 DEV+CONF 的完整来源/真值/拆分（oracle 真值仍只能离线评估器读取），对于 TRANSFER 只公开 `TR_id`、任务族、`sealed_manifest_sha256`；`transfer_registry_sealed.csv` 保存 TR 的真正名称、来源、私有测试与故障细节，仅由协调人保管，D 在代码和模板冻结且签署开封记录后获得。A/B/C 直到确认论文主实验结束也不得查看 sealed 表。四份任务书和四份最终包共享同一个**公开注册表 SHA**，迁移密封登记只以 commitment SHA 校验，不要求全员提前读取它。数据选择遵循：来源可访问且许可允许研究；目标和指标有独立权威说明；可建立与训练隔离的私有测试；四类真实成立；没有与 DEV/彼此的同源任务重复；样本规模及可运行成本满足冻结预算。若同一原始来源拆成多个任务，`source_group_id` 相同，并按来源进行独立性审查。

完整注册表在有相应访问权限的视图中 **每行一个基础任务**，至少包含：`task_id`, `split_tier`, `source_group_id`, `source_name`, `source_url`, `license`, `original_version`, `source_sha256`, `task_family`, `target_columns`, `target_semantics`, `primary_metric`, `metric_direction`, `id_columns`, `output_columns`, `output_mapping`, `valid_aliases`, `data_split_policy`, `split_seed`, `split_hash`, `oracle_version`, `applicability_notes`, `owner_signed_at`。缺关键字段不得从 DEV 晋升为正式任务。原始数据若禁止再分发，仅保存合法的下载指令、哈希和固定索引，而不是擅自打包。

3. 数据划分、隐藏真值与统一的公开信息边界

同一个 CONF/TRANSFER 任务在所有适用方法和成员间必须使用相同 `split_id`、相同样本 ID 集与相同私有测试标签。优先采用经过确认的官方独立划分；否则在正式运行前固定约 `60% fit / 20% validation / 20% private test`。分组数据按 group，时序数据按时间，多标签数据用适当的多标签划分，避免同对象或未来信息泄漏。训练内交叉验证只能使用 fit 部分；validation 用于事先定义的模型选择；private test 只能在离线评价器中读取。必须存储索引清单与哈希。

项目共同采用数据划分起始随机数 `1729`；实际拆分实现、库版本和每个任务的 `split_hash` 应成为冻结文件的一部分。开发随机块 `1101,1102`，正式确认随机块 `2101,2102,2103`，迁移随机块 `3101,3102,3103`。相同 seed 只是配对设计；云端 LLM 即便 seed 相同也可能不确定，必须记录真实模型 ID、参数、响应和操作时间（遵守服务使用条款及脱敏要求）。运行顺序在每个随机块内随机打散并记录，避免全部方法总按固定顺序运行。

私有 `C_gold` 是评估器持有的真实任务契约，不能传给 agent；`C_read` 是 agent 入口实际解析出的契约；`C_used` 是真实训练/预测动作消费的语义契约。必须分别存储。`oracle_gold/`、`private_test_labels/` 和 agent 工作目录须隔离；任何通过 prompt、工具上下文、日志提示、缓存或模型选择把隐藏真值提供给受测 agent 的案例均视为污染，主结果无效。若任务可见材料本身不足以唯一识别目标，应标记“需要澄清/不可辨识”，而非硬把隐藏答案当作 agent 应当猜中的真值。

信息可辨识层级固定： `I-A`＝从可见材料可判定唯一任务；`I-B`＝信息冲突、需要权威证据/澄清；`I-C`＝相同可见材料与两个不同真实意图兼容、原理上不可唯一判定。`I-C` 不能纳入“可检测故障召回”的分母；其适当行为是谨慎澄清/停止，而不是读取评估器私有答案。合法别名、合法类别映射及语义保持变换必须作为独立的干净负例。

4. 案例及故障模板固定，允许成员独立实现

共享案例**语义编码**如下，定义的是要测试的现象，而非全组共享同一个故障脚本。具体变异参数、注入实现和数据对象由各组独立实现并预注册。

- C00：原始干净任务。
- B01：输出列有明确合法别名/映射；B02：不改变对象的列顺序变化；B03：明确指定且可逆的类别顺序/目标变换；B04：无关提示/特征的措辞变化。这四类为**合法变化**，不应因字面不一致而被误拦。
- F01：训练目标缺失；F02：目标不应存在却泄漏到供预测的数据；F03：结构合法但目标提示误导；F04：输出集合与真实任务不一致；F05：入口后真实训练目标漂移；F06：任务类型漂移；F07：主指标/优化方向漂移；F08：类别概率顺序或逆变换错位；F09：ID 与预测角色混淆；F10：ID 集合及输出尺寸不变、但预测与 ID 行配对被置换。
- P01：目标提示与输出目标的复合冲突；P02：中间阶段漂移加输出语义漂移，必须检查全部真根因。
- A01：显性证据冲突且无法权威决定；A02：相同可见证据支持两种不同目标意图，属于不可辨识边界。
- I01：dtype/值域等完整性破坏；I02：必需特征/训练测试模式破坏。它们是扩展 I/O 范围，需与核心目标/提交语义分层报告。

每个正式 case_manifest 至少记录：case_id，task_id，template_id，condition，injection_stage，base_sha256，changed_paths，mutation_sha256，visible_evidence_hash，C_gold_version，truth_status，information_level，recoverable，expected_safe_action，target_fault_fields，expected_detection_stage，applicability，pre_registered_exclusion_reason。故障必须能够通过独立脚本验证**真的生效**；合法变化须有语义等价证明。一个案例因不适用而放弃，必须在看到模型结果前标 N/A + 原因；不得凭方法表现再挑案例。F02 人工测试泄漏不得把私有测试真实标签放入 agent 可见环境。

5. 四人共用的版本与对照方法字典

以下 ID 和定义只能在全体签字后版本化调整；**不可用同一个方法 ID 代指两个不同实现**。

- F0_ORIGINAL：从原稿真实代码 SHA 复现的完整 RTS-MA-DS，保留它**原有**的契约核查、reviewer 和默认 retry；只读 hook 通过行为等价 smoke 才可称为 F0。若旧代码不可取得或重现，标 not_reproducible，不得用自行实现版冒称原稿。
- F1_EXTENDED：在 F0 之上**实际增加**的新能力，例如真实 fit 绑定、后续执行检查、字段级定向修复、I/O 合同；每项要独立列出开关和提交 SHA，只能作为新版本研究，不能把其结果写成原论文旧系统成绩。F1 是可选增强，不是四人的硬依赖。
- M0_NO_SEMANTIC_ENFORCEMENT：reader、必要状态更新、正常路由与安全/资源限制不变，只取消研究性的任务语义阻断；关门控不允许把系统弄崩。
- M1_STRUCTURAL_STRONG：字段存在性、类型、shape、ID 合规等强结构规则；不得暗读真实意图。
- M2_INTAKE_ONLY_STRONG：**与对应 Full 使用相同入口 reader、初始语义规则和冻结契约**，只在入口实施语义检查，后续不做该语义持续核查；这是证明“多阶段增量”的核心强基线。
- M3_SHADOW：持续计算相同 reviewer 检查并私下记判决，但其判决**不改变执行、不额外透露诊断**给 agent。
- M4_END_ONLY：保留真实动作轨迹，在末端按事先声明的规则检查，可按相同预算执行末端补救，用于检验提前检查的时机价值。
- M5_BLOCK_ONLY：相关阶段执行同样的判决约束，发现违规即阻断，不提供定向修复，以区分“规避错误”和“完成任务”。
- G_GENERIC_RETRY：与拟比较的定向修复方法匹配次数、时间和模型调用预算，但没有字段级诊断信息；仅在存在实际定向修复实现时用于恢复归因。

主验证优先顺序： 确认“原稿方法”时主对比 F0_ORIGINAL vs M2_INTAKE_ONLY_STRONG；检验判决是否真实改变动作时用 F0 vs M3；若 F1 才具备运行中语义约束或定向修复，则 F1 vs M2/G 的结果是**新版方法**的贡献，不得反写为 F0。若代码检查证明 F0 与 M2 的入口后检查实际上相同，必须记录这一定义上的重合，不能制造虚假差异。

同一可比较对照的 agent 可见包、LLM/搜索后端、prompt 主体、预算、基础训练器、方法初始化、split 和 seed block 应尽可能相同；有不可能消除的框架固有差异时标为**系统级比较**，不能把差异归因于单个 gate。安全沙箱从不关闭。所有补丁必须先通过 `version_diff.csv` 和只读 hook 行为等价检验。

6. 预算、随机化、运行停止和重跑规则

保留原稿每阶段最多 3 次重试这一已报告设定，但明确 `retries` 与 `attempts` 的计数语义，并在代码中加断言。**任务级墙钟时间、模型调用/Token 上限、CPU/GPU/并发数、预算不等价时如何归一化**在冻结前填写到 `frozen_config.yaml`；先允许用 DEV pilot 测量耗时，不允许先看 CONF 结果再调整预算。强对照必须在同一剩余预算和同等可见证据下比较；字段级修复与普通重试的次数上限一致。

一个随机块是相同任务、案例、数据拆分、配置的配对标识，不代表两个独立数据集。原始 LLM 输出或行为变化必须落日志。若调用 API 失败或 GPU 不可用，先保留原运行的 `S8` 与错误日志；是否可重试、重试次数和重试后结果如何合并按预冻结规则执行，**不能重跑到得到有利结果为止**。不因中期效果不显著而随意加 seed，也不因结果好就提前停止确认。预设安全故障（例如泄露测试标签）可立即中止涉及的批次，并将受污染案例标识为不可用于确认。

默认各角色共用一个小型 DEV smoke／pilot 任务池：四类任务各 1 个，两个开发随机块；每位负责人依自己方法做必要 smoke，而非要求所有成员重复完全相同的大型 pilot。预实验只校验可执行性、案例真值、成本估计与观测完整性；**不会因为 F0 在 pilot 中不优于基线而判 pilot 失败**。

7. 唯一的八类最终结局与计量口径

每次实际启动的运行必须有且仅有一个互斥终态（没有启动的 `N/A` 不属于 S1–S8）：

1. `S1 DIRECT_CORRECT`：未发生真实修复，训练对象/指标/行对应与真值一致，输出有效。
2. `S2 REPAIRED_CORRECT`：至少发生一次实际修复，最终语义正确且输出有效。
3. `S3 JUSTIFIED_STOP_OR_CLARIFY`：依据可见信息确实不能安全继续，合理拒绝或澄清。
4. `S4 UNNECESSARY_ABORT`：原任务可解却被错误拒绝或合法变换被错误拦截。
5. `S5 SILENT_SEMANTIC_ERROR`：生成**看似有效**的预测文件，实际目标、指标、类别、变换或 `ID→预测` 关系不符真实任务。
6. `S6 INVALID_ARTIFACT`：提交格式/列/行/数值等明确交付条件不满足。
7. `S7 VISIBLE_EXECUTION_FAILURE`：工具或代码可见异常，未发生 S5 语义有效外观的错误交付。
8. `S8 BUDGET_OR_INFRA_FAILURE`：预算终止或 API/硬件中断，必须记录 `budget` 或 `infrastructure` 子原因。

优先处理同一次运行中的混合事件：若已生成并**正式交付**有效外观但语义错误的文件，主终态为 S5；若没有有效交付而崩溃则 S7；资源故障阻断判定时 S8；其他过程中出现的错误还可写在事件序列，不能偷偷出现两个终态。模棱两可的案例须由离线 oracle 裁定并留存异议记录。

主指标全部采用**实际启动运行数**作分母，另行给出所有计划格及 `N/A`：`correct_delivery=(S1+S2)/N_started`；`silent_error=S5/N_started`；`unnecessary_abort=S4/N_started`；`justified_stop=S3/N_started`。故障检测的 `TP/FN` 分母只包含事前标为可辨识且适用的真故障；合法误拦 `FP/TN` 分母只包含事前确认的合法场景；根因定位要另报 `exact_match`、部分匹配和无定位。正确停止不等于成功交付；发现“早停”不等于发现正确字段。

预测指标只在**语义正确且提交有效**的运行中报告，再同时给出“以全部启动为分母的正确任务交付率”；AUC、macro-F1、RMSE 不混合平均。资源报告：真实墙钟秒、错误目标 `fit` 训练秒、所有 API 调用数、确有可靠采集时的输入/输出 tokens 和收费；`每次正确交付成本 = 该方法全部启动运行的总成本 / (S1+S2 次数)`，成功次数为 0 时记 **undefined**，不能记 0。提前停止节省了错误训练时间也不能单独证明总体效率更好。

8. 统一统计计划及“有利创新”的预先定义

主统计单位是独立基础任务/独立数据来源，主配对键至少为 `(task_id, case_family, seed_block, host_id, model_id)`；因果同前缀实验还必须有**相同分叉前快照与候选动作哈希**。对每任务先汇总配对差，再给任务级均值、任务聚类 95% 区间、逐任务方向和留一任务敏感性；若多个任务来自同一源，需要更高层级

source_group_id 聚类。少量任务时区间本身也不稳，必须诚实表述。二项零事件要有适当上界，不能拿“0/24”宣称真实风险为零。

主方向预先定为 F0 相对 M2 的静默语义错误率减少，同时检查是否增加 S4、是否损害 S1+S2，以及成本。若 F0 逻辑等同 M2，则该主张无法由旧方法获得支持；只有明确新增机制并重新冻结研究计划，才能以 F1 建立新版主张。A 的 F0 vs M3 对动作层有效性是必要但不充分证据；C 的 F0 vs M2 对最终交付是核心；B 与 D 分别提供判定边界和外部有效性。

建议在 DEV 上预设两个**研究实用性容忍参考值**：合法/干净条件的正确交付率相对强基线损失不超过 5 个百分点，每正确交付成本相对增加不超过 20%。它们须经团队签字方可生效，**不是 TAI 官方门槛**，也不意味着 12 个任务足以作严格非劣效性证明。若置信区间不足以排除超过容忍界限的损失，应写“未排除有害权衡”，不能拿点估计替代非劣效检验。

四种结论必须区分：QC_PASS＝实验技术上合格；RESULT_USABLE＝对预先问题有可信、可复核的估计（包括负结果）；CLAIM_SUPPORTED_STRONG＝预设主对比呈有利方向且任务级 95% 区间与容忍权衡允许强措辞；CLAIM_DIRECTIONAL / NOT_SUPPORTED / INDETERMINATE＝仅趋势、结果反向或证据不足。**质量门控不会被设计成“Full 必须好于阈值才算过”。** 仅统计效果方向有利但区间跨 0，属于可报告的初步信号，不是统计确证。论文需报告所有预定比较，多重确认检验须在冻结计划中定义调整方案。

9. 通用科研实验质量门控：G0–G6

这些门控是**实验是否值得写入论文**的资格条件，不是算法自己的阻断规则；四人都要在 quality_gates.csv 中逐实验填写 PASS/FAIL/NA、证据文件、确认者和时间。

- G0 协议签字：FREEZE_SIGNOFF.yaml 存在，CONF 12 个任务的完整公开登记、TRANSFER 4 个任务的封存登记哈希、每项任务的拆分、base SHA、方法版本、预算、主指标、确认比较、seed、排除/重跑政策冻结；未签字只能做 DEV，不能声称 CONF 完成。
- G1 真值和案例：所有进入主分析的任务目标、适用性、合法等价或故障生效经独立单元测试验证；隐藏标签/答案与 agent 隔离；每个变更可回溯到唯一变异器及 hash；任何有污染的案例隔离，不用于主分析。
- G2 对照可运行：每个本组实际用到的方法通过 DEV smoke；至少两个干净 DEV 任务下基础工作流能正常到达有效终态。特别禁止把“关闭 reviewer 导致接口断裂”当作方法改善；需要真实阶段动作的实验必须证明 instrument/hook 工作。
- G3 运行账本闭合：每个计划格记 completed/N/A/not_started/infra_failed 等状态；每个实际启动必须落 S1–S8 之一、唯一 run_id 与原始日志；**100% 启动运行可追溯**。关键动作缺失只能单列“该动作指标不可判”，不能静默把该运行从主分母删掉。
- G4 比较与污染检查：同一配对的输入、split、seed、可见证据、预算和版本严格匹配或列出不可比较原因；同前缀因果实验分叉前状态和候选动作 hash 必须相同；private test 无泄漏；差异无法归因门控时不得称为局部因果证明。
- G5 统计与可再现：完整计划格或明确“部分矩阵”；可用冻结环境从**原始日志**重建逐次、逐任务结果及每张表图；人工核对至少 2 个有利和 2 个不利/失败记录（若没有有利例，核对全部失败/空事件），数值分子/分母一致。禁用挑最好 seed、偷偷重跑、事后换类别。
- G6 主张匹配：完成每个实验的 QC / USABLE / SUPPORT 三份独立判定，明确独立统计单位、置信区间、反例与适用范围；不因结果不利判实验失败，也不把故障注入比例当自然发生率。

在某个实验的 G0–G5 实施条件失败时，标 QC_FAIL 并说明污染范围；若只是效果不符合预期但技术条件通过，应标 QC_PASS, RESULT_USABLE, CLAIM_NOT_SUPPORTED。若完整矩阵未跑完，只能写“部分结果”，不能暗中用预定总数作分母。代码修复须另记版本、新的实验批次与首次发现日期，不能覆盖原日志。

10. 统一的计划规模、避免重复计算和并行协调

四人**共享基础任务，不共享方法成绩**，按各自工作负载独立执行：A 计划 144 个相同前缀、最多 720 条干预续跑和 72 条入口检查分支；B 在 12 个 CONF 上最多 252 个语义案例，最多 1764 次轻量判定；C 计划

12×5×4×3＝720 次端到端完整运行；D 的自然观察 12×2×3＝72 次、迁移 4×2×2×3×3×3＝432 次。上述数字是**计划上限/参考量**，不是当前完成数、也不是期刊硬规定；各自的 N/A 和不支持情况需依冻结协议报告。A 的续跑不是 720 个独立基础任务；B 的“判定调用”不是 1764 次完整训练；D 的 432 次仍只涉及 4 个封存基础任务。

开工分工：**项目协调人（可由作者本人担任）**唯一负责发布冻结的只读数据/协议快照、封存目录权限及合并后的事实核查，不需要替任一成员写代码或跑实验；A/B/C/D 各自配置运行器、变异器、离线 oracle、报告程序。成员可以提前在 DEV 做小规模独立开发；在 CONF/TRANSFER 的相应门控满足后直接运行自己路线。个人结果不得通过共享 PR 改动其他人的实验结果；真正需要的共享接口应在本人的 adapter 中完成并记录偏差。

每周只同步“协议问题、复现阻断和资源占用”，**不讨论 CONF 中途哪种方法赢、哪些任务对 Full 有利**。D 的 TRANSFER 目录及模板 hash 要封存到迁移冻结节点。跨路线最后用同一 `task_id` 与语义故障族建立**证据索引**，不能假定 A 与 C 在同一 task 上的不同 run 是一个实际因果轨迹。

11. 四人共用的开工签字清单（需要在正式运行前真实填写）

1. 原始 RTS 代码仓库地址、`base_commit`、有无旧故障包、各方法适配实现责任人：[待填]。
2. CONF 12 个任务的**正式名称、来源、许可证、SHA、目标、指标及拆分 hash**：[待填，见 `task_registry_public.csv`]；TRANSFER 4 个任务由协调人对 `transfer_registry_sealed.csv` 完整签字，四人共同记录其 seal SHA，D 按规定开封。
3. 原稿 F0 对应实现开关、M2 是否存在与 F0 是否行为不同、F1 是否计划新增：[待填]。
4. 每次完整运行的墙钟/LLM 额度、机器配置、并发数、API 模型 ID、版本、温度、提供商限制：[待填]。
5. 稳健性分层、确认主效应、若启用 5pp/20% 容忍界限的批准签字：[待填]。
6. 公共文件全套 SHA256、签署时间、签署人、封存任务解封时间/责任人：[待填]。

未填写不是“允许各自决定”，而是尚未具备正式 CONF/TRANSFER 研究的 G0 资格。 每个人收到 PDF 后可以在 DEV 开工，但必须以签字快照替换其结果包中的所有 [待填]。

第二部分　负责人 B 专项：故障覆盖、合法变化与信息边界

B 的职责与主要科学问题

B 独立构造有真值的故障、合法变化和不可判定情形，验证契约规则到底覆盖哪些语义错误，何时误拦正确任务，定位是否精确，以及在信息不充分时是否拒绝猜测。B 可以使用 12 个 CONF 基础任务，但不能依赖 A 的追踪器、C 的训练结果，更不能查看 D 封存任务。B 的工作主要是**判定能力与信息边界**，不能用低成本检查次数替代端到端模型训练的结论。

B0. 可运行的故障真值库和合法等价性检验（基础质量实验）

正式配置。 每个 CONF 任务最多 21 案例：原始 `C00` 1、合法 `B01–B04` 4、核心故障 `F01–F10` 10、复合 `P01–P02` 2、信息边界 `A01–A02` 2、扩展 I/O `I01–I02` 2；最多 **12×21=252** 个候选，实际适用性以签字案例表为准。**绝不可因为某种任务不适合类别概率/多标签而伪造案例。**

实施步骤。 (1) 使用与 A/C 完全相同的 12 个基础数据、oracle 与 split，只在本人空间生成变异；(2) 每例保存真实变动字段、哈希、oracle 真值、信息可见性、可恢复性、正确响应和最早可合理拦截阶段；(3) 建立自动验证程序：故障确实发生、结构保持故障没有意外 shape 错、合法变体前后语义/ID 映射等价、复合案例同时保留两个根因；(4) 对 `A02` 提供“两个不同隐藏意图—相同可见输入”的成对证据；(5) 由不看模型结果的审查确认有争议的真值与合法别名。

B0 质量门控。 正式案例的基础数据、变异器及真值 100% 有校验和；所有**适用且进入主分析**的案例均通过生效/语义等价单测；N/A 要在运行结果揭晓前登记并注明任务原理；`A02` 的可见输入 digest 必须相同而隐藏答案不同。不满足这些条件的案例不能算“有效真值”。

B0 结果可用。 形成可复核的 B_case_manifest.csv 和 21 类定义对照的适用性表；即使一些模板无法适用或与类别边界重叠，也能如实形成清晰评测范围。

B0 有利创新。 确认存在 (i) 普通形状/类型检查无法识别的结构合法语义故障，以及 (ii) 文本/列名表面不一致但真正合法的成对样例；它能说明研究问题值得测，但**仅构造案例尚不能证明新方法有效**。

论文材料。 T-B0：四类任务×21 个案例模板适用性及 oracle；B0_case_oracle_tests.csv；若遇到任务不支持概率多输出，提供 N/A 文字解释，不修改模板来讨好方法。

B1. 完整故障覆盖、准确定位与误拦截评估（主实验）

正式配置。 12 个 CONF 任务×最多 21 类案例×7 个规则/判定模式（M0、M1、M2、M3、M4、M5、F0）＝**最多 1764 次轻量判定或固定事件回放**；仅适用于相应位置的方法参与该 case，其他格在运行前标 N/A。该数目并非 1764 次模型训练，且判定器的性能统计单位不能直接当成 1764 个独立任务。

实施步骤。 (1) 对入口故障，在同一 agent 可见任务包上测各入口判定；(2) 对 F05–F10 的中后阶段故障，从 B 自己编写的状态/候选动作回放器构造实际字段和消费者不一致，入口-only M2 **不得偷看**后续状态；(3) 分别记录 approved / retry / fatal / clarify 以及最早正确拦截阶段；(4) 把 stop 与 localise 分成两列，定位须包含正确字段+来源阶段（复合故障 exact-match 只有全部根因命中才算）；(5) 在 C00+B01..B04 合法负例上测误拦截和无谓重试；(6) 对 F01–F10、P01/P02、I01/I02 分三组归纳，A02 不计普通召回分母。

主要指标。 故障检出 TP/(TP+FN)；合法误拦 FP/(FP+TN)；错判 fatal/retry 的代价；首次定位位置；根因集合 exact-match、partial-match；检测/回放耗时。每项写出分子与分母，按任务和任务族比较。M3 的 shadow 判决可评价诊断性能，但由于不阻断，不得把它的 “检测正确”写成“系统成功避免错误”。

B1 质量门控。 已验真的案例才进入分母；所有适用 (task,template,method) 可在账本找到 completed/N/A/failed；中后阶段错误真实位于入口之后；所有定位分数字段与 oracle 根因一致；合法负例没有被丢弃；每个方法开关有 freeze SHA。若没有状态回放证据却声称检测了训练时漂移，B1-QC_FAIL。

B1 结果可用。 能准确回答“哪些真故障被判断/定位”“哪些合法情况被误判”“何种错误仅靠入口一次性检查不可能发现”，即使 F0 漏检多数也能形成可用边界图。

B1 有利创新。 F0 在**结构合法且可辨识的目标/提交语义问题**上相对 M1 改善精确检出与定位，且对合法变体没有不可接受误拦；若声称持续多阶段，必须进一步表现为 F0 在真实后阶段故障上相对强 M2 的增量。若 F0 只优于弱 M0，贡献仅为加入验证而非新型语义机制。

论文表图。 T-B1：故障类型×方法的TP/FN/FP/TN和误拦分母；T-B2：复合故障完整定位/部分定位；F-B1：故障产生阶段×首次正确定位阶段热图；F-B2：检出收益—合法误拦权衡图。图可以用黑白灰度，不能掩盖漏检格子。

B2. 错误提示、合法别名与不充分信息的证据优先级

配置。 在 12 个 CONF 任务适用时构造 6 种可见证据条件：错误 hint 但无独立支持、hint 与训练模式冲突、任务说明权威但提交模板冲突、已明确给出合法别名、未给权威选择依据、加入合法的明确澄清。对 M1/F0 两种判定器，最多 **12×6×2＝144 次判定**；这些是 B1 的机制细分证据，若重复同一案例只引用已有判定，不虚增独立样本数。

操作。 (1) 使用配对可见输入，改变**仅一项**公开证据；(2) 记录解析优先级是来自任务文字、真实模式还是样本提交；(3) 给出 C_read 与 C_gold 的差异及诊断依据；(4) 对真值不可辨识的 A02，构造“同 E_visible/两个不同 C_gold”，不能用任何方法只看 E_visible 保证两者都正确；(5) 澄清条件要明确写出新增了哪一句权威信息并计算前后决策变化。

B2 质量门控。 不澄清的一对相同输入，其可见 digest 完全一致；隐藏真值离线保管；方法没有以 template_id、case_id 或 oracle 字段直接决定答案；澄清仅允许事前指定的证据增加，其他条件不变。

B2 结果可用。 能解释是 reader 选择了错误来源、合法别名误判，还是本来就不可唯一判定。即使不支持所主张的证据优先级，也可用于限定方法的适用条件。

B2 有利创新。 在可判定冲突中 F0 基于实际可见证据稳定正确解析、相对强结构检查有额外价值；对于真正不可判定者优先合理澄清而非高置信猜测。若它仅仅冻结了一个错误 `C_read`，不能说“跨阶段保持即可靠”。

论文材料。 `T-B3`：证据等级×方法决策矩阵；`F-B3`：相同格式/不同语义与不同字面/相同语义的成对轨迹，并注明哪些是哲学/信息边界而不是 Full 的失败。

B3. 覆盖面边界和结果复核（不额外挑选样本）

使用 B1/B2 原始记录按核心目标/提交、扩展 I/O、可辨识、不可辨识、入口、中阶段、末端和任务族分层。列出原稿 Table 5 的 `7/8 vs 0/8` 在新版任务定义下会怎样被归类，分类规则必须在结果前冻结。复核所有检测为正却最终字段定位为错的案例，以及导致合法任务误终止的案例。

B3 质量门控。 类别映射与根因判定可由 oracle 自动重建；不把 B1 的大量相关模板当作大量独立任务；全部假阳/假阴均可回溯。**结果可用**：可写明确的能力范围与不可辨识范围。**有利创新**：若不同语义家族中确有独立于 shape 检查的增量且误拦较低，可支撑“语义契约”而非通用 I/O 完整性的边界贡献。

B 的独立结束与最短交付检查

最终提交 `lane_B_final.zip`、`lane_B_evidence_report.pdf`；最少包含 252 候选案例中的真实适用/不适用对照、1764 判定格的完整账本（可能部分 N/A）、真实阶段回放器、独立 oracle、三张主要表和至少两张统计图；首页回答：**普通结构检查没识别的语义错误有哪些？误拦了哪些合法场景？能否定位完整根因？信息不足时是否承认不知道？原稿门控真的有多阶段检测增量吗？**

第三部分　四人共同且完全一致的代码、数据、结果与论文交付标准

1. 最终到底交什么给项目负责人？

每位负责人最终提交两件物品：`lane_X_final.zip`（X 为 A/B/C/D；可复现实验包）和 `lane_X_evidence_report.pdf`（建议 4–8 页**普通文字＋必要统计图表**的结果解释）。实验包中必须同时包含可运行代码、原始证据、全部计划格索引、统计脚本、结果表图和失败/反例。只给汇总 Excel、截图、几条精简日志或论文措辞，**不算通过交付验收**。TXT/MD 源文档可作为辅助，但不能替代机器可读的主记录。

目录及文件名必须遵循共同协议，以便在不等其他人代码的情况下独立打开与重建：

```
lane_X_final/
  README.md                  # 一页运行说明、研究问题、完成率、主要发现
  BASE_COMMIT.txt            # 原稿 SHA、本分支 SHA、方法哈希
  FREEZE_SIGNOFF.yaml        # 四人完全相同的签字冻结协议快照
  CHANGELOG.md               # F0 / 只读观测 / F1 的版本差异
  SHA256SUMS                 # 案例、配置、日志和表图的哈希索引
  protocol/
    PROTOCOL.md              # 与四份 PDF 的共同协议同版
    task_registry_public.csv # DEV/CONF 完整信息；TR 仅 ID 与密封哈希
    split_registry.csv       # 来源、拆分和隐藏测试 hash
    frozen_config.yaml      # 模型、预算、依赖、seed、温度、硬件
    methods.yaml             # 方法 ID 与真实实现开关
    outcomes.yaml            # S1-S8 与判分优先级
    analysis_plan.md         # 预注册主指标、对比、CI、N/A 规则
    deviations.csv           # 冻结后所有变动/例外及时间
  env/
    environment.lock         # requirements.lock / conda.lock / 镜像摘要
    runtime_info.json        # OS、CPU/GPU、服务模型真实 ID
  src/
    adapters/                # 自己路线实现，独立于其他 lane
    oracle/                  # 离线判分器，运行时与 agent 物理隔离
  cases/
    manifest.csv             # 每个基础任务和案例、适用性、故障真值
    mutation_specs/          # 有版本/哈希的变异器参数与脚本
  scripts/
    smoke.py                 # 最小检查，能自动输出门控结果
    run.py                   # --dry-run / --pilot / --confirm / --resume
    evaluate.py              # 独立 oracle，八种终态与正确任务评分
    analyze.py               # 任务级配对统计、CI 与敏感性
```

```
  make_paper_assets.py     # 从原始记录重建全部论文表图
logs/
  plan_ledger.csv          # 包括未启动/N/A 的全矩阵
  run_index.csv            # 唯一 run_id、路径、SHA、状态
  events/*.jsonl           # 每次运行的真实判决/动作/模型/交付事件
  errors/                  # API/工具/硬件错误、失败重试和回溯
outputs/
  artifact_index.csv       # 产物 hash、判分、缺失/无效原因
results/
  run_level.csv            # 一启动一行，失败不得删
  pair_level.csv           # 同任务/同前缀可比性键
  task_level.csv           # 独立任务级效果、区间和方向
  resource_ledger.csv      # 时间、调用、训练浪费、缺失计量
  quality_gates.csv        # G0–G6 + 本 lane 每实验门控
  claims.csv               # QC/USABLE/SUPPORT 的三层结论
paper/
  tables/*.csv             # 正文/附录每张表的数字及分母
  figures/*.pdf            # 简洁黑白论文图，由脚本生成
  figures/*.png            # 查阅预览
  cases/*.md               # 正例、反例、无效例及事件 ID
  evidence_report.pdf      # 本人成果的可写作结论与局限
reproduce.sh               # 只使用本目录与合法外部数据来源
```

task_registry_public.csv 只包含 A/B/C 可见的 DEV/CONF 细节与 TRANSFER 封存哈希；A/B/C 不得提前得到 TRANSFER 名称、私有标签或故障内容。D 的有权限私有副本应在封存开封后单独归档。若有关文件因版权/API 许可不能入 ZIP，应交**非敏感引用索引、合法获取命令、哈希和权限说明**，并在 README 中明确是否可完全公开复现。密钥只能通过环境变量读取，禁止打包 API Key、测试标签明文或匿名投稿受限文稿。

2. 所有 lane 的最少日志字段：必须逐行可连接

plan_ledger.csv：plan_cell_id, lane_id, stage, task_id, source_group_id, condition, template_id, case_id, method_id, host_id, model_id, seed_block, planned_status, applicability, n_a_reason, freeze_sha。每个计划格都在运行前生成，执行后更新状态；主论文标明实际启动数、完成数、N/A、未运行数，不可把 N/A 记为失败率分母中的 0。

run_level.csv：run_id, plan_cell_id, pair_id, task_id, source_group_id, case_id, case_family, method_id, implementation_sha, split_hash, oracle_version, prompt_sha, config_sha, seed_block, host_id, model_id, started_at, finished_at, terminal_S, terminal_subreason, semantic_correct, artifact_valid, actual_fit_target_hash, actual_metric, output_mapping_valid, rejected_valid_case, wall_seconds, wrong_training_seconds, api_calls, tokens_in_if_observed, tokens_out_if_observed, measured_cost_if_observed, artifact_sha256, event_trace_path, exception_path, missingness_reason。确实无法观测的字段必须写 NA 及原因，不能写 0；不能靠 agent 自评来填 semantic_correct。

events.jsonl：每条至少含 event_id, run_id, monotonic_seq, timestamp, phase, actor, event_type, state_hash, candidate_hash, contract_digest, source_fields, verdict, next_action, actual_fit_target_hash, artifact_mapping_digest, error_subtype。应能从 reviewer 判决追到真实 fit/predict 或合理停止，且顺序单调。可复核性最好提供至少一条正向和一条反向的完整轨迹索引。

quality_gates.csv：experiment_id, gate_id, status, checked_count, eligible_count, evidence_path, reason, checked_by, checked_at。claims.csv：claim_id, experiment_id, primary_contrast, estimand, units, estimate, ci_low, ci_high, qc_status, result_usable, support_level, counterexample_ids, allowed_paper_wording。任何论文中的“改善百分比”都应能返回这些记录核验。

3. 代码提交最低验收：不靠作者口述即可运行

1. ./reproduce.sh --smoke 从干净环境加载冻结配置并完成最小测试；需要外部私有数据时明确 DATA_ROOT 与下载授权，不能偷偷使用作者本机绝对路径。
2. python scripts/run.py --dry-run 打印实际矩阵、计划数、N/A 和成本预估；--pilot 与 --confirm 分阶段运行，--resume 能以唯一 run_id 恢复，绝不覆盖已存在的完成日志。

3. 同一个源文件只做一次 SHA256 登记；环境/接口变更带新 `implementation_sha`，所有无门控、shadow 和检查变体能够通过配置独立运行，不能修改共享源文件“硬切换”后丢失版本。
4. `python scripts/evaluate.py` 离线读取 oracle/私有测试，不依赖 agent 主观自述；对八终态、输出行映射、误拦、预算失败均有固定单元测试。
5. `python scripts/analyze.py` 由全部启动运行生成分母和配对统计；`python scripts/make_paper_assets.py` 自动重建每张表/图，并保存图表至运行文件及统计单位的溯源索引。
6. 除必要第三方外，不允许依赖 `../lane_A`、`../lane_B`、`../lane_C`、`../lane_D` 等别人的私有目录。若发现不可移植，提交前调整为自己的 adapter 或经签字公开的共同 package。

以上命令是**交付时要求成员真实实现并测试的接口规范**，不是声称当前已有可以直接执行的脚本。

4. 什么程度的记录足以用来撰写 TAI 论文?

Methods: 可以精确定义 F0 的契约、检查频率、路由权、失败语义和可观察动作；若实际实现不同于论文伪代码，能用代码差异与完整版本审计说明。要有 F0 对照、强 M2 的算法/接口差别，不用代理文字叙述代替源码。

Experimental setup: 每个任务有来源、目标、私有测试隔离证明、分层和独立性；每个故障有代码、可恢复性、正确响应/字段与可见信息；每个方法有真实预算和输入；所有不支持格子、技术故障和除外规则可公开复核。

Main results: 每一个主效应都有完整分母、独立任务数、置信区间、逐任务差、比较方法、三类完整终态风险（静默错、正确交付、误拦），不采用 `best-of-three` 或只统计“能写出文件”的系统。若 12 个任务得不出精确结论，可以如实报告不确定性，并考虑预先注册的独立扩展，而不是复制 seed 增加名义样本数。

Mechanism evidence: 事件轨迹能从 `C_read` 到真实 `fit`/提交映射，再到 gate 决策和分叉后结局；至少一个可核对的正向案例及一个不支持该主张的反例（若真实不存在正向案例，说明不存在，不得捏造）。同前缀比较还提供状态与候选动作 hash。

Boundary and transfer: 故障覆盖须报告“合法变体误拦”与不可判定问题；自然漂移须说明注入与非注入区别；迁移须报告两个宿主、两个模型家族和未见模板在每个单元的真实运行情况、失效组合和精度限制。

Paper assets: 每张图/表有文件源、生成命令、归一化方式、配对层级和引用的原始运行索引；正文不要出现源文件里无法核验的新数字。给出一份“证据链矩阵”：主张 → lane → 实验 ID → 表图编号 → 最小复现命令 → 支持/限制/反例。

5. 负责人最终怎样验收四个实验包?

- **交付合格（PACKAGE_PASS）**：压缩包结构、冻结快照、原始日志、失败记录、重现脚本、图表都齐全；能在清洁环境完成 smoke，并重建本人的主要表格。否则退回补齐，即使图表方向很有利也不算完成。
- **结果可用（RESULT_USABLE）**：基础任务独立性、案例真值、对照公平、终态完整、配对估计和不确定性符合本 lane 的问题；负结果同样可能可用。若数据污染、对照失效、哈希不匹配或主分析没有完整分母，应标 `NOT_USABLE` 并说明需重跑哪部分。
- **创新支持（CLAIM_SUPPORTED）**：A 证明动作层因果，B 证明语义边界的额外检测价值，C 证明端到端静默错误减少并保留正确交付，D 给出自然问题证据/真实封存迁移。四项共同支持**有条件的、证据可跟踪的** TAI 主线；单项漂亮结果不能替代其他环节，负结果可能导致主张收窄或方法升级。

论文最终总结时，还必须给四条证据链之间的**一致性审计**：相同语义故障在 A 的动作差、B 的定位差、C 的终态差是否方向兼容；若不兼容说明原因，不要把不同成员不相干的 run 硬拼成一条实际因果样本。是否达到 TAI 的发表水平还取决于方法原创性、相关工作定位及证据规模，**门控通过并非期刊接受保证**。