非注入自然错误实验

准备工作已完成；真实模型实验等待 API 配置

本次交付是什么？

按照用户最新要求，先完成不需要 DeepSeek API 的部分。已建立独立分支、原始数据哈希、144 格 DEV 矩阵、运行与续跑接口、只读观测、离线判分、统计脚本和测试。本报告是准备状态说明，不是完成 4.pdf 全部实验的结果报告。

首页问题	当前可核验回答
自然错误是否真实观察到？	尚未进行真实 DeepSeek 运行。N_started=0，错误率为 NA，不能写成 0/144。
如何区别普通执行失败？	S5 要有外观有效交付和真实动作语义错误证据；崩溃为 S7，格式/值域问题为 S6，预算或基础设施问题为 S8。
第二宿主、第二模型上是否优于 M2？	未测试。没有第二宿主、第二模型家族或已开封迁移任务。
现在允许怎样外推？	只支持准备与离线兼容性结论；不支持自然风险发生率、门控收益或跨环境泛化。

已完成的验证

25 项单元与轨迹回放测试通过。Titanic 与 Ghouls 各进行一次无观测、一次有观测的离线工作流运行，均完成，配对预测文件 SHA256 完全一致。所有离线运行使用原系统回退路径，不调用模型 API，不进入自然错误统计分母。

实验设计与原始数据边界

不注入故障；不修改 CSV；不提供隐藏评估答案

层级	计划	当前状态
DEV 自然观察与门控对照	8 数据集 × 3 描述 × 2 随机块 × 3 方法 = 144	未启动真实模型运行
正式 D0 自然观察	12 CONF × 2 宿主 × 3 随机块 = 72	共享签字与任务未冻结
正式 D1 封存迁移	4 × 2 宿主 × 2 家族 × 3 条件 × 3 块 × 3 方法 = 432	未开封；当前不执行故障注入迁移

任务与描述

使用原稿已有的 Spaceship Titanic、Titanic、Bank Churn、Academic Success、Ghouls、Obesity Risk、Steel Plate Defect、House Prices。P0 为简短原意，P1 增加“ 训练并预测测试行 ”的说明，P2 明确按原始文档和提交模板交付；三个版本都不添加错误目标、指标或误导事实。

随机性与独立性

开发块为 1101、1102；设置 Python random、NumPy 和 PYTHONHASHSEED。原稿内部固定的 estimator/CV 种子保持不变，原服务接口也没有 LLM seed 参数。因此它们是配对运行块，不代表独立数据集或保证不同的训练随机性。144 次重复只涉及 8 个已用于旧稿的 DEV 任务。

数据与评分限制

原始文件逐一登记 SHA256，运行前校验，ZIP 不重分发原始数据。原测试标签不可得，不能报告独立 held-out 准确率。离线判分依据原始说明、真实 fit 输入及预测/ID 映射。Steel 仅作原稿复现，不能作为新“ 真正多标签 ”外部确认任务。

对照方法与证据链

保留正常路由；不通过删 reviewer 制造系统失败

方法	实现与可解释边界
F0_ORIGINAL	原稿 app 未修改；只读钩子记录真实动作。当前只完成离线行为等价检查。
M2_INTAKE_ONLY_STRONG	入口 reader 和规则相同，保留结构性后续检查。原稿没有额外的冻结语义持续核查可移除，故本实现与 F0 范围重合。
M0（仅 reviewer 层消融）	仅去掉入口 target unresolved / target leakage 语义阻断；保留文件/提交结构检查和必要状态更新。reader 仍进行目标解析，属于 reviewer 层消融。

每次运行记录什么？

记录模型请求与响应、实际返回模型 ID、入口 target_spec、各节点状态、真实 Pipeline.fit 的 y 摘要与文件、训练使用指标、预测输入、序列化前后输出、reviewer 判决及终态。私有 oracle 不被 agent 进程导入；观测不把诊断反馈给 agent。

目前可确认什么？

两个离线原始任务的有/无观测输出完全相同。F0 与 M2 没有独立的持续语义算法差异，因此后续即使出现随机差异，也不能当作门控增量因果证据。M0 也不能被描述为完全没有任务理解的独立 AutoDS 框架。

还需真实模型校验

API 别名计划为 deepseek/deepseek-flash，用户指定显示名为 DeepSeek 4.1 Flash；尚未收到任何服务响应，不能声称已验证版本。真实运行还需验证观测覆盖、模型身份、成本和边界案例；不能把离线回退行为称为自然 LLM 漂移。

判分、统计与质量门控

没有实际观测时保留 NA；不把计划数量当作样本量

项目	预先定义
主对比	F0-M2 的 S5、S1+S2、S4，同时报告 S8 和资源；披露范围重合。
配对与区间	同任务、描述、随机块、宿主、模型配对；先任务内汇总，再按任务 bootstrap 和留一任务分析。
终态	每次启动一行，S1-S8 互斥；普通错误不冒充静默语义漂移；未观测/无法核验不判成功。
失败与续跑	保留失败原始记录；--resume 跳过已启动格，不能不断重跑直至成功。
无标签限制	不报告模型预测准确率；不同指标不混合平均；不把未知成本记为零。

质量状态

共享 FREEZE_SIGNOFF.yaml 保持与 lane_A 相同的未签字快照。G0 不通过，正式 CONF/TRANSFER 不能启动。离线基础测试通过；真实模型观察完整性、独立复核和迁移门控尚未完成。

三类验收必须分开

准备包可复现，不等于正式 PACKAGE_PASS；真实数据尚不存在，不满足 RESULT_USABLE；更不能声称 CLAIM_SUPPORTED。results/claims.csv 和 D_claim_ledger.md 明确列出当前不支持的结论。

交付索引

logs/plan_ledger.csv：144 格 DEV；logs/formal_plan_ledger.csv：504 格正式计划；results/smoke.json：离线等价证据；protocol/source_files.csv：原文件哈希；paper/tables/：当前分母和 NA；results/quality_gates.csv：逐项质量状态。

复现与下一步

代码准备完成；等待用户稍后提供本机 API 配置路径

一、无需 API 可立即复现

用 Python 3.13 和 env/environment.lock 建立独立环境；将 LANE_D_BASE 指向固定原稿提交的仓库。执行 reproduce.sh --prepare、--smoke、--dry-run、--rebuild。ZIP 不依赖其他 lane 的私有目录；原始公开仓库来源与提交 SHA 均记录在包内。

二、补齐 API 后先做小规模真实 pilot

设置 LANE_D_ENV_FILE 为本机私有环境文件路径，使用 scripts/run.py --pilot --limit 2。保存响应模型 ID，核验返回值、真实 fit 与交付记录，测量 API 调用和耗时。真实模型验证通过后再 --resume 完成预登记矩阵；不改原始数据、不临时扩 seed 追求有利结果。

三、对预算的诚实说明

每格最多 60 次服务调用、1,800 秒墙钟，顺序执行。144 格理论上限为 8,640 次调用、72 小时顺序墙钟。这只是保护上限，不是实测消耗或费用估算。成本必须等真实 pilot 与服务计费记录后计算。

四、完整任务 4 仍缺什么？

自然错误实跑及人工证据审查；共享 CONF 签字与任务注册；独立第二宿主；不同模型家族；封存任务和模板的预注册、签字、开封及迁移实验。当前用户选择先做 API-free 工作，因此这些明确保留为未完成，而不是静默省略。

当前可写入工作进度的结论

“ 已准备基于八个原稿数据集的非注入 DEV 实验，覆盖三种一致描述和两个过程随机块；两个任务上的离线观测等价检查通过。真实模型运行与外部迁移尚待开展。 ”